ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG

BÁO CÁO TIẾN ĐỘ & KẾT QUẢ THỰC NGHIỆM
KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

XÂY DỰNG VÀ ĐÁNH GIÁ PROTOTYPE HỆ THỐNG PHÁT HIỆN XÂM NHẬP IOT SỬ DỤNG FEDERATED LEARNING TRONG MÔI TRƯỜNG DỮ LIỆU NON-IID

Sinh viên thực hiện: Nguyễn Việt Kỳ Quân – 23521267
Cán bộ hướng dẫn: PGS. TS. Lê Trung Quân
Ngành đào tạo: Mạng máy tính và An toàn thông tin
Khóa học: 2022 – 2026

TP. HỒ CHÍ MINH, NĂM 2026

Abstract

Sự bùng nổ của mạng lưới Internet vạn vật (IoT) đã mở rộng đáng kể bề mặt tấn công mạng, đòi hỏi các giải pháp Phát hiện Xâm nhập Mạng (NIDS) hiệu quả và bảo toàn quyền riêng tư. Học liên đoàn (Federated Learning – FL) nổi lên như một hướng tiếp cận đầy triển vọng cho phép các thiết bị biên phối hợp huấn luyện mô hình phân tán mà không cần tập trung hóa dữ liệu lưu lượng thô. Tuy nhiên, tính phi đồng nhất về mặt thống kê (Non-IID) và hiện tượng mất cân bằng lớp cấu trúc cực đoan giữa các trạm mạng IoT biên đặt ra rào cản kỹ thuật nghiêm trọng đối với quá trình hội tụ và độ chính xác của mô hình.

Báo cáo này trình bày kết quả thực nghiệm của đề tài Khóa luận Tốt nghiệp, định vị bản chất là một **Nghiên cứu Thực nghiệm và Đo kiểm Hệ thống (Empirical Benchmarking Study)**. Nghiên cứu khảo sát hiệu năng phân loại của mô hình học máy nhẹ `TabularIoTMLP` ($14,024$ tham số, dung lượng ≈ 54.28 KB) trên tập dữ liệu chuẩn CICIoT2023 với hơn 5.1 triệu dòng dữ liệu luồng mạng và tỷ lệ mất cân bằng lên tới $147.11 : 1$. Thông qua chuỗi 10 kịch bản thực nghiệm đối chứng có kiểm soát (từ E1 đến E6) được phân tách thành mô hình tập trung (Centralized Baseline), dữ liệu đồng nhất (IID), chuỗi lệch phân phối Dirichlet Non-IID ($\alpha \in \{1.0, 0.5, 0.1\}$), và kiểm tra tính mở rộng quy mô ($K \in \{5, 7, 10\}$ clients), nghiên cứu mang lại 3 đóng góp khoa học thực chất:

1. **Bằng chứng thực nghiệm phản biện (Empirical Counter-Evidence / Negative Finding):** Trong khi mô hình tập trung (E1) nhận diện tốt các lớp tấn công thiểu số (đạt tỷ lệ Recall lớp `Web-based` là 52.41% và `Brute-force` là 53.36%), việc phân tán qua FedAvg làm tỷ lệ phát hiện `Web-based` sụp đổ xuống 1.66% ($K = 5$) và 0.39% ($K = 10$), và bị dập tắt hoàn toàn về 0.00% ở FedProx. Điều này chứng minh sự thất bại của các lớp thiểu số là hệ quả toán học của phép lấy trung bình gia quyền n_k/N và hiện tượng triệt tiêu tính dẻo cục bộ (Loss of Local Plasticity) của số hạng phạt proximal, chứ không phải do khiếm khuyết dung lượng biểu diễn của mô hình.

2. **Hiệu năng vượt trội ở các lớp tấn công thể tích lớn:** Hệ thống liên đoàn đạt tỷ lệ nhận diện xuất sắc đối với các mối đe dọa hạ tầng nghiêm trọng: Mirai Botnet đạt F1-score 98.78% (Recall 99.88%), DDoS đạt F1-score 88.38% (Precision 90.45%), Spoofing đạt F1-score 83.98%, và lưu lượng hợp lệ (Benign) đạt F1-score 80.31%.

3. **Vạch ra đường cong suy thoái Dirichlet định lượng và Đánh đổi đa chiều:** Xác định chính xác ngưỡng gãy đổ $\alpha \leq 0.5$ và sự sụp đổ nghiêm trọng tại $\alpha = 0.1$ (Macro-F1 sụt giảm từ 68.00% xuống 43.01%, mất tới 25% hiệu năng). Đồng thời, chứng minh chi phí truyền thông tăng tuyến tính hoàn hảo theo quy mô client (5.30 MB $\rightarrow$ 7.42 MB $\rightarrow$ 10.60 MB) với độ ổn định F1 cao trong môi trường IID.

Trên cơ sở đó, đề tài xây dựng đề xuất thuật toán **Decoupled Federated Learning (FedPer/FedRep)** tách biệt tầng trích xuất đặc trưng chung và tầng phân loại cá nhân hóa, định hình lộ trình nghiên cứu tiếp theo nhằm giải quyết triệt để sự suy thoái Non-IID cực đoan trong an ninh mạng IoT.

Keywords: Federated Learning, IoT Intrusion Detection, Non-IID Data, Dirichlet Distribution, FedAvg, FedProx, Decoupled FL, CICIoT2023, Flower gRPC.

Table of Contents

Abstract **i**

List of Acronyms and Abbreviations **vii**

I Introduction **1**
I.1 Background and Research Motivation 1
I.2 Core Challenges in Distributed IoT Networks 1
I.3 Research Objectives and Scope 2
I.4 Research Positioning and Scientific Contributions 3
I.5 Thesis Organization 3

II Literature Review **5**
II.1 CICIoT2023 Benchmark Dataset 5
II.2 Federated Learning Foundations and Baseline Algorithms 6
II.2.1 Federated Averaging (FedAvg) Algorithm 6
II.2.2 Parameter Client Drift Phenomenon 6
II.2.3 Federated Proximal (FedProx) Algorithm 6
II.3 Non-IID Data Modeling via Dirichlet Distribution 7
II.4 Recent Related Works and Comparative Analysis (2022–2026) 7
II.5 Identified Research Gaps 8

III Methodology **9**
III.1 Controlled Empirical Benchmarking Methodology 9
III.2 Data Partitioning Strategies 9
III.3 Lightweight TabularIoTMLP Model Architecture 10
III.4 Multi-dimensional Evaluation Framework and Metrics 10

IV Implementation **11**
IV.1 Experimental Testbed and Infrastructure 11
IV.2 Distributed System Implementation on Flower gRPC 11
IV.2.1 Custom Aggregation Strategy and Server Evaluation 11
IV.3 Data Preprocessing Pipeline and Leakage Control 12
IV.4 Local Training Pipeline and FedProx Integration 12

V Testing Scenarios, Results, and Discussions **13**
V.1 Experimental Scenario Matrix and Benchmark Setup 13
V.2 Master Benchmark Results and Synthesis 14
V.3 In-depth Analysis of Core Scientific Findings 14

V.3.1 Finding 1: Empirical Counter-Evidence on Minority Class Collapse (Negative Finding) . . . 14
V.3.2 Finding 2: Superior Detection Performance on High-Volume Infrastructure Attacks . . . 16
V.3.3 Finding 3: Quantified Dirichlet Degradation Curve and Scalability Analysis . . . 17
V.3.4 Finding 4: Cross-Regime Invariance of the Stability-Plasticity Trade-Off and Multi-Condition Pareto Frontier . . . 18
V.4 Objective Analysis of System Limitations and Defense-in-Depth Positioning . . . 20

VI Conclusions and Future Work **22**
VI.1 Summary of Research Achievements . . . 22
VI.2 Roadmap for In-Progress and Pending Scenarios . . . 22
VI.3 Long-Term Research Directions . . . 23

A Class Distribution Details in CICIoT2023 **25**

B Experimental Hyperparameter Configurations **26**

List of Figures

V.1 Comparison of normalized confusion matrices between Centralized Baseline E1 and Federated FedAvg E2. 16
V.2 Per-class Recall comparison demonstrating minority class collapse in federated settings. 16
V.3 Global Macro-F1 convergence trajectories across 10 communication rounds. . . 18
V.4 Comparison of optimization trajectories under extreme Non-IID skew $\alpha = 0.1$. 18
V.5 Multi-regime empirical analysis of the Stability-Plasticity trade-off across IID, $\alpha = 0.5$, and $\alpha = 0.1$: (a) Parameter drift stabilization, (b) Global Macro-F1 utility, (c) Minority class extinction cliff at $\mu \geq 0.01$, and (d) 2D Pareto trade-off plane. 19

List of Tables

II.1 Comparative analysis between this work and recent FL-IoT-IDS studies (2022–2026). 8

V.1 Master benchmark results of the FL-IoT-IDS system on CICIoT2023 across 20 experimental scenarios. 15

V.2 Detailed per-class classification performance of FL-IoT-IDS (Scenario E2 FedAvg IID). 17

A.1 Sample distribution of 8 attack classes in the CICIoT2023 dataset. 25

B.1 Uniform hyperparameter configurations across experimental scenarios. 26

List of Acronyms and Abbreviations

AI	Artificial Intelligence
CIC	Canadian Institute for Cybersecurity
CNN	Convolutional Neural Network
CPU	Central Processing Unit
DDoS	Distributed Denial of Service
DL	Deep Learning
DoS	Denial of Service
FedAvg	Federated Averaging
FedProx	Federated Proximal
FL	Federated Learning
gRPC	Google Remote Procedure Call
IDS	Intrusion Detection System
IID	Independent and Identically Distributed
IoT	Internet of Things
ML	Machine Learning
MLP	Multi-Layer Perceptron
NIDS	Network Intrusion Detection System
Non-IID	Non-Independent and Identically Distributed
OOM	Out Of Memory
RAM	Random Access Memory
ReLU	Rectified Linear Unit
SOTA	State-Of-The-Art
TCP/IP	Transmission Control Protocol / Internet Protocol
UIT	University of Information Technology (VNU-HCM)
WAF	Web Application Firewall

Chapter I

Introduction

I.1 Background and Research Motivation

Sự phát triển vượt bậc của công nghệ vi điện tử và truyền thông không dây đã thúc đẩy làn sóng bùng nổ của mạng lưới Internet vạn vật (Internet of Things – IoT). Từ các hạ tầng đô thị thông minh, hệ thống giám sát y tế, đến các dây chuyền sản xuất tự động hóa công nghiệp (IIoT), hàng tỷ thiết bị thông minh đang liên tục kết nối và trao đổi dữ liệu qua mạng viễn thông toàn cầu. Tuy nhiên, sự tiện ích này đi kèm với sự mở rộng nghiêm trọng của bề mặt tấn công mạng (attack surface). Hầu hết các thiết bị IoT biên (Edge IoT) được thiết kế với ngân sách năng lượng và năng lực tính toán hạn chế, thiếu vắng các cơ chế bảo mật phần cứng nghiêm ngặt, biến chúng thành những mắt xích yếu nhất trong chuỗi an ninh mạng và mục tiêu hấp dẫn cho các cuộc tấn công diện rộng như từ chối dịch vụ phân tán (DDoS), mạng máy tính ma (Botnet Mirai), hay xâm nhập đánh cắp dữ liệu [1].

Để chủ động phát hiện và ngăn chặn các nguy cơ an ninh, các Hệ thống Phát hiện Xâm nhập Mạng (Network Intrusion Detection System – NIDS) dựa trên Học máy (Machine Learning – ML) và Học sâu (Deep Learning – DL) đã được triển khai rộng rãi [2]. Trong mô hình học máy tập trung truyền thống (Centralized ML), toàn bộ dữ liệu lưu lượng mạng thô (raw packet captures hoặc network flow records) từ các trạm biên phải được tổng hợp về một trung tâm dữ liệu hoặc máy chủ đám mây (Cloud Datacenter) để phân tích và huấn luyện mô hình. Phương thức tiếp cận này hiện bộc lộ hai rào cản kỹ thuật cốt tử:

1. **Vi phạm quyền riêng tư và quy định bảo vệ dữ liệu:** Lưu lượng mạng biên chứa đựng các thông tin định danh cá nhân nhạy cảm, topology nội bộ của hạ tầng mạng doanh nghiệp, và thói quen sinh hoạt của người dùng. Việc truyền tải tập trung dữ liệu thô đối mặt với nguy cơ rò rỉ dữ liệu và vi phạm nghiêm trọng các quy định pháp lý an toàn thông tin quốc tế (như GDPR, ISO/IEC 27701) [3].

2. **Nghẽn cổ chai băng thông truyền thông:** Hàng triệu thiết bị IoT liên tục phát sinh hàng terabyte dữ liệu mỗi ngày. Việc đẩy toàn bộ luồng mạng qua đường truyền Internet diện rộng (WAN) dẫn đến tắc nghẽn băng thông, độ trễ truyền dữ liệu cao, và chi phí hạ tầng mạng vượt quá khả năng chịu tải của các nút mạng biên.

I.2 Core Challenges in Distributed IoT Networks

Học liên đoàn (Federated Learning – FL) do McMahan et al. [4] khởi xướng đã mang lại lời giải đột phá cho bài toán bảo vệ quyền riêng tư: các nút mạng biên giữ lại toàn bộ dữ liệu cục bộ,

chỉ huấn luyện mô hình tại chỗ và định kỳ gửi các tham số trọng số ($\mathbf{w}$) về máy chủ trung tâm để tổng hợp thành mô hình toàn cục. Tuy vậy, khi ứng dụng mô hình học liên đoàn vào bài toán NIDS trên mạng IoT thực tế, các nhà nghiên cứu phải đối mặt với ba thách thức kỹ thuật lớn:

1. **Dữ liệu phi đồng nhất (Non-IID Statistical Heterogeneity):** Trong thế giới thực, mỗi gateway hoặc thiết bị IoT chỉ quan sát một góc nhìn hạn chế về lưu lượng mạng tùy thuộc vào vị trí địa lý, chức năng nghiệp vụ và các loại thiết bị kết nối đằng sau nó. Phân phối dữ liệu giữa các client có sự dị biệt sâu sắc (khác biệt phân phối nhãn $P_k(y)$ và phân phối có điều kiện $P_k(x|y)$). Sự phi đồng nhất này dẫn tới hiện tượng trôi dạt tham số cục bộ (*Client Drift*), làm chệch hướng hội tụ của thuật toán Federated Averaging (FedAvg) và suy giảm nghiêm trọng độ chính xác toàn cục [5, 6].

2. **Mất cân bằng lớp cấu trúc cực đoan (Severe Structural Class Imbalance):** Trong môi trường mạng viễn thông thực tế (như phản ánh trong tập dữ liệu chuẩn CICIoT2023), lưu lượng tấn công thể tích lớn (DDoS, DoS) chiếm hơn 70% tổng lưu lượng, trong khi các cuộc tấn công tinh vi, nguy hiểm cao như Web-based (SQL Injection, XSS) hay Brute-force chỉ chiếm dưới 0.5%. Khi dữ liệu bị phân tán qua nhiều nút, các lớp đa số áp đảo hoàn toàn tín hiệu cập nhật gradient, khiến mô hình phân tán có nguy cơ mù hoàn toàn trước các mối đe dọa hiếm gặp [7].

3. **Giới hạn tài nguyên phần cứng thiết bị biên (Resource Constraints):** Các trạm mạng IoT biên có bộ nhớ RAM và năng lực CPU hạn chế, không thể vận hành các mô hình cồng kềnh (như Transformer hay CNN-LSTM phức tạp) vốn đòi hỏi dung lượng tải trọng trao đổi lên đến hàng chục megabyte mỗi vòng liên đoàn [8].

I.3 Research Objectives and Scope

Đề tài Khóa luận Tốt nghiệp tập trung giải quyết các mục tiêu khoa học cụ thể sau:

- Khảo sát, chuẩn hóa và phân vùng tập dữ liệu chuẩn an ninh mạng IoT CICIoT2023 theo các mức độ dị biệt thống kê có kiểm soát bằng phân phối Dirichlet ($\alpha \in \{1.0, 0.5, 0.1\}$) và chuẩn đồng nhất IID.

- Thiết kế và hiện thực mô hình nơ-ron nhẹ `TabularIoTMLP` tối ưu cho dữ liệu bảng 39 đặc trưng dòng mạng, bảo đảm kích thước tham số nhỏ gọn (≈ 54.28 KB) phù hợp với ràng buộc phần cứng IoT biên.

- Triển khai hệ thống đo kiểm phân tán sử dụng Flower framework qua giao thức gRPC socket thực, đánh giá trực tiếp hai giải thuật tổng hợp nền tảng là FedAvg và FedProx.

- Xây dựng chuẩn đối chứng tập trung (Centralized Upper-bound) trên cùng một kiến trúc mạng và tập dữ liệu để phân tách rõ ràng ảnh hưởng của năng lực mô hình với ảnh hưởng của cơ chế tổng hợp phân tán.

- Định lượng hóa toàn diện tam giác đánh đổi giữa: Hiệu năng phân loại (Utility – Macro-F1, Minority Recall), Chi phí tài nguyên (Cost – Communication payload), và Khả năng mở rộng quy mô (Scalability – số lượng trạm $K \in \{5, 7, 10\}$).

I.4 Research Positioning and Scientific Contributions

> **Tuyên bố Định vị Bản chất Công trình:** Đề tài này được định vị là một **Nghiên cứu Thực nghiệm và Đo kiểm Hệ thống (Empirical Benchmarking Study)**. Mục tiêu của khóa luận là cung cấp các bằng chứng đo kiểm thực nghiệm có kiểm soát, trung thực và chính xác về mặt định lượng, vạch ra ranh giới kỹ thuật và bản chất toán học của các thuật toán FL hiện hành khi ứng dụng vào an ninh mạng IoT.

Lưu ý miễn trừ về mặt đóng góp kỹ thuật (Engineering Disclaimer): Đề tài khẳng định rõ ràng rằng: *Việc xây dựng hệ thống mô phỏng phân tán Flower gRPC, thiết lập đường truyền socket mạng đa tiến trình, hay tối ưu hóa bộ nhớ dữ liệu chỉ là cơ sở hạ tầng thực nghiệm và phương tiện kỹ thuật (experimental plumbing) nhằm thu thập số liệu đo kiểm khách quan. Toàn bộ các công tác kỹ thuật này KHÔNG cấu thành đóng góp khoa học của đề tài.*

Bỏ qua các hình thức kỹ thuật bề nổi, giá trị khoa học thực chất của khóa luận bao gồm 3 đóng góp sau:

1. **Bằng chứng thực nghiệm phản biện về giới hạn nhận diện lớp thiểu số (Empirical Counter-Evidence / Negative Finding):** Bằng việc thiết lập đối chứng trực diện giữa mô hình tập trung (E1) và mô hình liên đoàn (E2–E6) trên cùng một không gian kiến trúc `TabularIoTMLP`, nghiên cứu chỉ ra rằng: khi huấn luyện tập trung, mô hình MLP đạt tỷ lệ Recall trên lớp `Web-based` là 52.41% và `Brute-force` là 53.36%. Tuy nhiên, khi chuyển sang môi trường học liên đoàn, tỷ lệ này sụp đổ xuống 1.66% ($K = 5$) và 0.39% ($K = 10$) ở FedAvg, và bị dập tắt hoàn toàn về 0.00% ở tất cả các kịch bản FedProx. Kết quả thực nghiệm này cung cấp bằng chứng đanh thép bác bỏ giả định lạc quan trong nhiều công bố lý thuyết, chứng minh rằng sự thất bại với lớp thiểu số là hệ quả toán học tất yếu của cơ chế trung bình trọng số mẫu n_k/N và hiện tượng triệt tiêu tính dẻo cục bộ (*Loss of Local Plasticity*) của số hạng phạt proximal.

2. **Xác lập tính bất biến quy luật suy thoái và Đường cong biên Pareto đa điều kiện (Multi-Regime Pareto Frontier):** Khác với phần lớn các công trình công bố chỉ thử nghiệm tại một điểm dữ liệu duy nhất ($\alpha = 0.5$), nghiên cứu này thiết lập chuỗi đối chứng bậc thang có kiểm soát gồm 20 kịch bản: IID $\rightarrow \alpha = 1.0 \rightarrow \alpha = 0.5 \rightarrow \alpha = 0.1$. Đặc biệt, nghiên cứu thực hiện khảo sát toàn diện dải siêu tham số $\mu \in \{0.001, 0.01, 0.025, 0.05\}$ xuyên suốt 3 điều kiện (IID, $\alpha = 0.5$, $\alpha = 0.1$), lần đầu tiên chứng minh tính bất biến quy luật của "Vực thẳm tuyệt chủng lớp thiểu số"khi $\mu \geq 0.01$ và xác lập điểm ngọt Pareto phổ quát tại $\mu = 0.001$ giúp kiềm chế trôi dạt tham số từ $78.7\% - 90.8\%$ trong khi vẫn bảo toàn tính dẻo nhận diện các mối đe dọa hiếm.

3. **Khung đánh giá đánh đổi đa chiều và Khả năng mở rộng quy mô (Trade-off and Scalability Framework):** Đo lường toàn diện chi phí truyền thông thực tế (chỉ tiêu tốn 5.30 MB $\rightarrow 10.60$ MB cho toàn bộ 10 rounds huấn luyện), chứng minh tính ổn định tuyệt đối khi mở rộng quy mô $K = 5 \rightarrow 7 \rightarrow 10$ trong môi trường IID (biến thiên Macro-F1 $< 0.72\%$). Trên nền tảng các phát hiện thực nghiệm, đề tài xác lập cơ sở dữ liệu đối chuẩn thực nghiệm định lượng về sự đánh đổi giữa băng thông, độ trôi dạt tham số và độ chính xác phân loại mạng IoT.

I.5 Thesis Organization

Báo cáo khóa luận được cấu trúc thành 6 chương chính theo đúng chuẩn mực khoa học:

- **Chapter I – Introduction:** Bối cảnh và động lực nghiên cứu, các thách thức cốt lõi của mạng IoT, mục tiêu, phạm vi và tuyên bố định vị 3 đóng góp khoa học thực chất của đề tài.
- **Chapter II – Literature Review:** Tổng quan tập dữ liệu CICIoT2023, nền tảng toán học của FedAvg, hiện tượng Client Drift, thuật toán FedProx, mô hình hóa Non-IID qua phân phối Dirichlet, ma trận đối sánh các công trình gần đây (2022–2026) và các khoảng trống nghiên cứu.
- **Chapter III – Methodology:** Phương pháp luận nghiên cứu đối chứng không rò rỉ dữ liệu, chiến lược phân vùng IID/Dirichlet, thiết kế kiến trúc mạng `TabularIoTMLP`, và hệ tiêu chí đánh giá đa chiều.
- **Chapter IV – Implementation:** Trình bày cơ sở hạ tầng thử nghiệm (testbed plumbing), cơ chế giao tiếp socket gRPC trên Flower, chiến lược tổng hợp tùy biến, pipeline tiền xử lý và quy trình huấn luyện cục bộ.
- **Chapter V – Testing Scenarios, Results, and Discussions:** Bảng tổng hợp Master Benchmark 20 kịch bản (E1–E6), phân tích chuyên sâu 4 phát hiện khoa học, đường cong biên Pareto đa điều kiện, phân tích ma trận nhầm lẫn, thảo luận hạn chế kỹ thuật và định vị Phòng thủ chiều sâu (Defense-in-Depth).
- **Chapter VI – Conclusions and Future Work:** Tổng kết các kết quả đạt được, kế hoạch hoàn thiện kiểm chứng đa hạt giống, cùng các hướng mở rộng dài hạn (E7 Decoupled FL).

Chapter II

Literature Review

II.1 CICIoT2023 Benchmark Dataset

Tập dữ liệu CICIoT2023 [1] là một trong những chuẩn đánh giá (benchmark dataset) quy mô lớn và chân thực nhất hiện nay cho các hệ thống NIDS trong môi trường IoT. Bộ dữ liệu được xây dựng bởi Viện An ninh mạng Canada (CIC) dựa trên mô hình thử nghiệm vật lý gồm 105 thiết bị IoT thực tế (bao gồm camera an ninh, bóng đèn thông minh, cảm biến gia dụng, gateway và thiết bị trung tâm điều khiển), kết nối qua các giao thức mạng phổ biến như Wi-Fi, Zigbee, và Z-Wave.

Bộ dữ liệu chứa hơn 47 triệu bản ghi dòng dữ liệu mạng (network flows). Mỗi bản ghi bao gồm 39 đặc trưng số (numerical statistical flow features) mô tả các thuộc tính thống kê của gói tin như: độ dài gói tin trung bình, phương sai độ dài, thời gian giữa các gói tin (Inter-Arrival Time – IAT), các cờ điều khiển giao thức TCP/UDP, và tốc độ truyền luồng [9]. Toàn bộ các cuộc tấn công bao gồm 33 biến thể tấn công chi tiết, được chuẩn hóa và gom nhóm thành 8 phân lớp lớn:

1. **Benign (Lưu lượng hợp lệ):** Chiếm 21.46% tổng số mẫu ($1,098,191$ dòng).
2. **DDoS (Từ chối dịch vụ phân tán):** Chiếm 37.57% tổng số mẫu ($1,922,002$ dòng) – lớp chiếm đa số tuyệt đối.
3. **DoS (Từ chối dịch vụ đơn nguồn):** Chiếm 14.27% tổng số mẫu ($730,344$ dòng).
4. **Reconnaissance (Dò quét mạng):** Chiếm 13.50% tổng số mẫu ($690,534$ dòng).
5. **Spoofing (Giả mạo địa chỉ/ARP):** Chiếm 8.34% tổng số mẫu ($426,604$ dòng).
6. **Mirai (Mã độc mạng botnet IoT):** Chiếm 4.12% tổng số mẫu ($210,823$ dòng).
7. **Web-based (Tấn công tầng ứng dụng web – SQLi, XSS, Command Injection):** Chiếm 0.49% ($24,829$ dòng).
8. **Brute-force (Dò quét mật khẩu qua từ điển):** Chiếm 0.26% ($13,064$ dòng) – lớp thiểu số cực đoan.

Tỷ lệ mất cân bằng giữa lớp lớn nhất (DDoS) và lớp nhỏ nhất (Brute-force) lên tới $147.11:1$. Đây chính là đặc trưng thực tế của không gian mạng viễn thông: các cuộc tấn công lũ lụt đường truyền xảy ra với mật độ gói tin dày đặc, trong khi các cuộc tấn công khai thác lỗ hổng tinh vi chỉ phát sinh vài chục gói tin nhưng lại có sức phá hoại mục tiêu vô cùng nghiêm trọng.

II.2 Federated Learning Foundations and Baseline Algorithms

II.2.1 Federated Averaging (FedAvg) Algorithm

Thuật toán Federated Averaging (FedAvg) do McMahan et al. [4] đề xuất là nền tảng của học liên đoàn. Giả sử hệ thống có K trạm biên tham gia. Mỗi trạm k sở hữu một tập dữ liệu cục bộ $\mathcal{D}_k$ với số lượng mẫu là n_k. Tổng số mẫu toàn mạng là $N = \sum_{k=1}^{K} n_k$. Mục tiêu tối ưu toàn cục là tìm vector trọng số $\mathbf{w}$ tối thiểu hóa hàm mất mát:

$$\min_{\mathbf{w}} F(\mathbf{w}) = \sum_{k=1}^{K} \frac{n_k}{N} F_k(\mathbf{w}) \quad \text{với} \quad F_k(\mathbf{w}) = \frac{1}{n_k} \sum_{i \in \mathcal{D}_k} \ell(f(\mathbf{x}_i; \mathbf{w}), y_i) \tag{II.1}$$

Trong đó $\ell(\cdot)$ là hàm mất mát (như Cross-Entropy Loss). Tại mỗi vòng giao tiếp $t \in \{1, 2, \ldots, T\}$:

1. Máy chủ trung tâm phát tán vector trọng số toàn cục $\mathbf{w}_t$ xuống tập các client được lựa chọn.

2. Mỗi client k khởi tạo mô hình cục bộ bằng $\mathbf{w}_t$, sau đó thực hiện E epochs huấn luyện bằng giải thuật Stochastic Gradient Descent (SGD) hoặc AdamW trên dữ liệu nội bộ $\mathcal{D}_k$, thu được vector trọng số cục bộ mới $\mathbf{w}_{t+1}^{(k)}$.

3. Các client gửi vector trọng số $\mathbf{w}_{t+1}^{(k)}$ về máy chủ. Máy chủ thực hiện tổng hợp tham số theo trung bình gia quyền:
$$\mathbf{w}_{t+1} = \sum_{k=1}^{K} \frac{n_k}{N} \mathbf{w}_{t+1}^{(k)} \tag{II.2}$$

II.2.2 Parameter Client Drift Phenomenon

Trong điều kiện dữ liệu phân phối đồng nhất (IID), gradient cục bộ $\nabla F_k(\mathbf{w})$ là ước lượng không chệch của gradient toàn cục $\nabla F(\mathbf{w})$, bảo đảm mô hình hội tụ nhanh chóng. Tuy nhiên, khi dữ liệu phân tán bị lệch phân phối (Non-IID), mục tiêu tối ưu của các client bị phân kỳ: $\arg\min F_k(\mathbf{w}) \neq \arg\min F(\mathbf{w})$. Các bước cập nhật cục bộ độc lập sau E epochs sẽ kéo vector trọng số của từng client di chuyển về các hướng cục bộ đối nghịch nhau. Khoảng cách trôi dạt tham số (*Client Drift*) tại vòng t được định lượng bằng chuẩn L_2:

$$\Delta \mathbf{w}^{(k)} = \|\mathbf{w}_{\text{local}}^{(k)} - \mathbf{w}_{\text{global}}^{(t)}\|_2 = \sqrt{\sum_{l} \|\mathbf{w}_{\text{local}}^{(k,l)} - \mathbf{w}_{\text{global}}^{(t,l)}\|_2^2} \tag{II.3}$$

Khi $\Delta \mathbf{w}^{(k)}$ quá lớn, phép tính trung bình số học (II.2) tại máy chủ sẽ kéo vector mô hình về một vị trí trung gian không tối ưu cho bất kỳ phân phối cục bộ nào, dẫn đến hiện tượng dao động nghiệm, suy giảm hiệu năng nghiêm trọng, hoặc phân kỳ hoàn toàn [6].

II.2.3 Federated Proximal (FedProx) Algorithm

Để kiểm soát hiện tượng trôi dạt tham số do tính phi đồng nhất về mặt thống kê, Li et al. [5] đề xuất thuật toán FedProx. Trong FedProx, bài toán tối ưu cục bộ tại mỗi client k được bổ sung thêm một số hạng phạt điều hòa khoảng cách (proximal term):

$$\min_{\mathbf{w}} h_k(\mathbf{w}; \mathbf{w}_t) = F_k(\mathbf{w}) + \frac{\mu}{2} \|\mathbf{w} - \mathbf{w}_t\|_2^2 \tag{II.4}$$

Trong đó $\mu \geq 0$ là siêu tham số phạt điều hòa (proximal parameter). Số hạng $\frac{\mu}{2}\|\mathbf{w} - \mathbf{w}_t\|_2^2$ đóng vai trò như một sợi dây neo đàn hồi (elastic anchor), ngăn không cho vector nghiệm cục bộ dịch chuyển quá xa khỏi mô hình toàn cục $\mathbf{w}_t$ nhận được từ server. Về mặt lý thuyết toán học, số hạng phạt này làm cho hàm mục tiêu cục bộ có tính lồi mạnh hơn (strongly convex), giúp ổn định hóa quá trình hội tụ trong môi trường mạng không đồng nhất.

II.3 Non-IID Data Modeling via Dirichlet Distribution

Để mô phỏng hiện tượng lệch phân phối nhãn (Label Distribution Skew) một cách có kiểm soát và khoa học, nghiên cứu áp dụng phương pháp phân vùng dữ liệu dựa trên phân phối Dirichlet nhiều chiều theo chuẩn mực của Hsu et al. [6].

Với mỗi lớp tấn công $c \in \{1, 2, \ldots, C\}$ (với $C = 8$), một vector tỷ lệ phân bổ $\mathbf{p}_c = (p_{c,1}, p_{c,2}, \ldots, p_{c,K})$ được lấy mẫu từ phân phối Dirichlet:

$$\mathbf{p}_c \sim \text{Dir}(\alpha \cdot \mathbf{1}_K) \tag{II.5}$$

Trong đó $\mathbf{1}_K$ là vector gồm K phần tử bằng 1, và $\alpha > 0$ là tham số tập trung (concentration parameter):

- Khi $\alpha \to \infty$, vector $\mathbf{p}_c \to (1/K, 1/K, \ldots, 1/K)$, dữ liệu của mỗi lớp được chia đều hoàn hảo cho tất cả các client, tương đương với trạng thái phân phối đồng nhất IID.
- Khi $\alpha = 1.0$, dữ liệu bắt đầu xuất hiện sự chênh lệch phân phối vừa phải giữa các nút mạng (Non-IID nhẹ).
- Khi $\alpha = 0.5$, mức độ tập trung tăng cao, một số client bắt đầu thiếu hụt hoàn toàn một số lớp tấn công nhất định (Non-IID trung bình).
- Khi $\alpha \to 0$ (ví dụ $\alpha = 0.1$), phân phối bị phân mảnh cực đoan: hầu hết các mẫu của lớp c sẽ chỉ tập trung vào duy nhất một hoặc hai client, trong khi các client còn lại hoàn toàn không quan sát thấy lớp này.

II.4 Recent Related Works and Comparative Analysis (2022–2026)

Để làm rõ vị trí học thuật của đề tài, Bảng II.1 tổng hợp phân tích đối sánh chi tiết giữa nghiên cứu này và các công bố khoa học tiêu biểu giai đoạn 2022–2026 trên tập dữ liệu CICIoT2023 và bài toán FL-NIDS.

Table II.1: Comparative analysis between this work and recent FL-IoT-IDS studies (2022–2026).

Reference	**Architecture & Algorithm**	**Data Partitioning**	**Unresolved Limitations**
Alahmari et al. (2025) [7]	Deep Neural Network, FedAvg	Sử dụng mạng sinh đối kháng (GANs) để tăng cường mẫu nhân tạo	Chi phí sinh dữ liệu GANs không khả thi trên thiết bị IoT biên; không đo lường trôi dạt tham số (Drift).
Albanbay et al. (2025) [8]	CNN / MLP, FedAvg	Khảo sát mở rộng tỷ lệ mẫu trên CICIoT2023	Chỉ thử nghiệm trên 1 mốc Non-IID cố định; bỏ qua đánh giá chi phí truyền thông tích lũy.
Huang et al. (2022) [2]	MLP / FedAvg	Phân vùng Non-IID trên các tập dữ liệu cũ	Tập dữ liệu cũ, không đại diện cho lưu lượng IoT hiện đại; không phân tích lớp thiểu số.
This Work (Empirical Benchmark)	**TabularIoTMLP (14k parameters), FedAvg & FedProx**	**Centralized Baseline E1, controlled Dirichlet ladder** $\alpha \in \{1.0, 0.5, 0.1\}$	**Vạch ra bằng chứng phản nghiệm về sự sụp đổ lớp thiểu số; xác lập ngưỡng gãy đổ** $\alpha \leq 0.5$**; đo kiểm toàn diện tam giác Utility – Cost – Scalability.**

II.5 Identified Research Gaps

Từ việc phân tích tổng quan tài liệu, đề tài xác định 3 khoảng trống nghiên cứu cốt lõi mà các công trình trước đây chưa giải quyết thấu đáo:

1. **Khoảng trống về Phân tích Nguyên nhân Thất bại (Negative Finding Gap):** Các bài báo thường chỉ công bố độ chính xác tổng thể (Accuracy $> 90\%$), vô tình che giấu việc mô hình hoàn toàn mất khả năng phát hiện các lớp tấn công hiếm ($< 0.5\%$). Thiếu vắng các nghiên cứu đối chứng có kiểm soát giữa học tập trung và học phân tán trên cùng một tập dữ liệu để chứng minh cơ chế nào làm sụp đổ lớp thiểu số.

2. **Khoảng trống về Đường cong Suy thoái Định lượng (Dirichlet Spectrum Gap):** Đa số công bố chỉ chọn ngẫu nhiên một giá trị α duy nhất, không cung cấp một phổ suy thoái liên tục để chỉ ra cho các kỹ sư mạng biết: tại ngưỡng α cụ thể nào thì hệ thống FL bắt đầu mất kiểm soát.

3. **Khoảng trống về Đo kiểm Đánh đổi Toàn diện (Multi-dimensional Trade-off Gap):** Các nghiên cứu thường tách rời việc đo độ chính xác với chi phí băng thông truyền thông hai chiều và sự ổn định khi mở rộng quy mô nút biên.

Chapter III

Methodology

III.1 Controlled Empirical Benchmarking Methodology

Nghiên cứu áp dụng phương pháp luận đo kiểm thực nghiệm có kiểm soát nghiêm ngặt (Controlled Empirical Benchmarking). Để bảo đảm tính trung thực khoa học và loại bỏ hoàn toàn hiện tượng rò rỉ dữ liệu (Data Leakage), quy trình phân chia và tiền xử lý dữ liệu được thiết kế theo các nguyên tắc chuẩn mực sau:

1. **Phân tách Tập Kiểm định Toàn cục Độc lập (Global Holdout Test Set):** Toàn bộ tập dữ liệu CICIoT2023 ($5,116,391$ mẫu) được phân chia ngẫu nhiên thành 70% tập phát triển ($3,581,473$ mẫu) và 30% tập kiểm định toàn cục tương lai ($1,534,918$ mẫu). Tập kiểm định 30% này được cô lập hoàn toàn, không bao giờ tham gia vào quá trình huấn luyện cục bộ tại các client, và được dùng làm thước đo duy nhất để đánh giá mô hình toàn cục của tất cả các kịch bản thực nghiệm.

2. **Chuẩn hóa không rò rỉ tri thức (Leakage-Free Normalization):** Phép biến đổi chuẩn hóa `RobustScaler` (sử dụng trung vị và khoảng tứ phân vị IQR để chống nhiễu ngoại lai) chỉ được khớp (`fit`) trên tập dữ liệu huấn luyện, sau đó áp dụng phép chuyển đổi (`transform`) một chiều lên tập kiểm định.

3. **Chuẩn đối chứng Tập trung (Centralized Upper-bound Baseline):** Thiết lập kịch bản E1 huấn luyện mô hình trên toàn bộ 70% dữ liệu tập trung với cùng kiến trúc `TabularIoTMLP` để xác định trần hiệu năng lý thuyết tối đa mà kiến trúc này có thể đạt được khi không có sự cản trở của môi trường phân tán.

III.2 Data Partitioning Strategies

Tập 70% dữ liệu huấn luyện được phân vùng cho K client theo hai phương thức:

- **Phân vùng IID (Stratified Random Sampling):** Dữ liệu của từng lớp được xáo trộn ngẫu nhiên và phân bổ đồng đều theo tỷ lệ mẫu vào K client, bảo đảm phân phối xác suất tiên nghiệm của nhãn $P_k(y)$ tại mọi client là tương đương nhau.

- **Phân vùng Non-IID Dirichlet:** Sử dụng phân phối Dirichlet $\mathrm{Dir}(\alpha)$ trên từng nhãn với các mức tham số $\alpha \in \{1.0, 0.5, 0.1\}$. Khi $\alpha = 0.1$, hiện tượng phân cực nhãn xảy ra cực đoan, mô phỏng chính xác các mạng con IoT chuyên biệt trong thực tế (ví dụ: phân khúc mạng chỉ toàn camera giám sát bị tấn công Mirai, trong khi phân khúc máy chủ web chỉ gặp tấn công SQLi).

III.3 Lightweight TabularIoTMLP Model Architecture

Mô hình `TabularIoTMLP` được thiết kế tối ưu hóa cho dữ liệu bảng 39 đặc trưng dòng mạng, cân bằng giữa năng lực phi tuyến và tính gọn nhẹ cho thiết bị IoT biên:

- **Tầng đầu vào (Input Layer):** Tiếp nhận vector đặc trưng kích thước 39.
- **Tầng ẩn 1 (Hidden Layer 1):** Kết nối tuyến tính Linear$(39, 128)$, hàm kích hoạt phi tuyến ReLU, kết hợp tầng điều hòa Dropout(0.2) để chống hiện tượng quá khớp (overfitting).
- **Tầng ẩn 2 (Hidden Layer 2):** Kết nối tuyến tính Linear$(128, 64)$, hàm kích hoạt ReLU.
- **Tầng đầu ra (Output Classifier Head):** Kết nối tuyến tính Linear$(64, 8)$ đưa ra điểm số logit cho 8 phân lớp tấn công.

Tổng số lượng tham số của mô hình là $14,024$ tham số kiểu số thực 32-bit (`float32`), tương đương với kích thước payload chỉ ≈ 54.28 KB. Đây là kích thước lý tưởng cho phép lưu trữ trọn vẹn trong bộ nhớ SRAM của các vi điều khiển IoT công nghiệp hoặc router biên mà không gây quá tải tài nguyên phần cứng.

III.4 Multi-dimensional Evaluation Framework and Metrics

Nghiên cứu thiết lập hệ thống đo kiểm đa chiều để đánh giá toàn diện hệ thống:

1. **Độ chính xác Tổng thể (Accuracy):** Tỷ lệ dự đoán đúng trên tổng số mẫu kiểm định.
2. **Macro-Averaged F1-score (Macro-F1):** Trung bình cộng điểm F1 trên toàn bộ 8 phân lớp:
$$\text{Macro-F1} = \frac{1}{C}\sum_{c=1}^{C} F1_c = \frac{1}{C}\sum_{c=1}^{C} \frac{2 \times \text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \tag{III.1}$$
Đây là chỉ số quan trọng nhất phản ánh tính công bằng của mô hình đối với tất cả các lớp, ngăn chặn việc chỉ số tổng thể bị làm sai lệch bởi các lớp đa số (DDoS).
3. **Minority Recall (Tỷ lệ Phát hiện Lớp Thiểu số):** Đo lường khả năng bắt trúng các cuộc tấn công hiếm gặp: `Web-based` (0.49%) và `Brute-force` (0.26%).
4. **Chi phí Truyền thông Tích lũy (Cumulative Communication Cost):** Tổng dung lượng trao đổi hai chiều giữa Server và K client qua mạng gRPC sau T rounds:
$$\text{CommCost} = 2 \times \sum_{t=1}^{T} m_t \cdot B \tag{III.2}$$
Với m_t là số client tham gia tại round t, và $B = 54.28$ KB là kích thước vector trọng số mô hình.
5. **Độ trôi Tham số Trung bình (Average Client Drift):** Đo khoảng cách Euclidean giữa vector mô hình cục bộ và mô hình toàn cục để định lượng sự phân kỳ thống kê:
$$\overline{\text{Drift}} = \frac{1}{K}\sum_{k=1}^{K} \|\mathbf{w}_{\text{local}}^{(k)} - \mathbf{w}_{\text{global}}\|_2 \tag{III.3}$$

Chapter IV

Implementation

IV.1 Experimental Testbed and Infrastructure

> *Lưu ý miễn trừ trách nhiệm khoa học:* Toàn bộ nội dung trong chương này mô tả cơ sở hạ tầng thực nghiệm và các kỹ thuật hiện thực hóa phần mềm được xây dựng để phục vụ việc thu thập số liệu đo kiểm một cách tự động, ổn định và có khả năng tái lập. Các công tác kỹ thuật này chỉ là phương tiện thực thi (testbed plumbing), hoàn toàn không cấu thành đóng góp khoa học của luận văn.

Hệ thống đo kiểm được tổ chức thành 4 phân tầng kỹ thuật có kiểm soát:

1. **Phân tầng Quản lý Dữ liệu và Phân vùng (Data & Partitioning Layer):** Quản lý việc đọc các tệp CSV nén của CICIoT2023, tiền xử lý, lưu trữ bộ nhớ đệm (caching) và chia phân vùng theo file ánh xạ index định sẵn.
2. **Phân tầng Trạm Biên Liên đoàn (Federated Client Layer):** Quản lý các tiến trình client độc lập vận hành mô hình PyTorch `TabularIoTMLP`.
3. **Phân tầng Máy chủ Điều phối và Tổng hợp (Federated Server Layer):** Vận hành máy chủ Flower Server quản lý vòng đời huấn luyện liên đoàn.
4. **Phân tầng Giám sát và Đo kiểm Đa chiều (Evaluation & Monitoring Layer):** Tự động ghi nhận log chi tiết, đo thời gian huấn luyện, tính toán độ trôi L_2 norm, và xuất các biểu đồ trực quan hóa.

IV.2 Distributed System Implementation on Flower gRPC

Hệ thống sử dụng nền tảng Flower (phiên bản $1.13.0$) kết nối qua giao thức Google Remote Procedure Call (gRPC). Mỗi client chạy trên một tiến trình hệ điều hành riêng biệt, thiết lập kết nối TCP/IP socket thực với Server tại địa chỉ cổng chỉ định.

IV.2.1 Custom Aggregation Strategy and Server Evaluation

Lớp `AggregateCustomStrategy` được hiện thực hóa bằng cách kế thừa trực tiếp từ chiến lược cơ sở của Flower (`flwr.server.strategy.FedAvg` và `FedProx`):

- **Tổng hợp tham số:** Thực hiện tính trung bình gia quyền vector trọng số gửi về từ các client hợp lệ sau mỗi round.

- **Đánh giá toàn cục tập trung (Centralized Evaluation):** Sau mỗi round tổng hợp, máy chủ tự động nạp vector trọng số toàn cục mới nhất vào một mô hình đánh giá độc lập, chạy suy luận trên toàn bộ $1,534,918$ mẫu của tập kiểm định toàn cục 30%. Quá trình này bảo đảm kết quả đo lường giữa các vòng là hoàn toàn nhất quán và không phụ thuộc vào dữ liệu phân mảnh của client.
- **Lưu trữ Checkpoint tối ưu:** Hệ thống tự động theo dõi chỉ số Macro-F1 toàn cục sau mỗi round; trọng số đạt đỉnh cao nhất được lưu trữ vào tệp `best_weights.npz` để sử dụng cho việc phân tích ma trận nhầm lẫn cuối cùng.

IV.3 Data Preprocessing Pipeline and Leakage Control

Module tiền xử lý (`src/data/preprocess.py`) thực hiện tuần tự các bước:

1. Loại bỏ các dòng chứa giá trị khuyết thiếu (NaN) hoặc giá trị vô hạn (Inf) phát sinh trong quá trình tính toán thống kê dòng mạng.
2. Ánh xạ 33 nhãn tấn công chi tiết về 8 lớp chính theo chuẩn phân loại của bộ dữ liệu CICIoT2023.
3. Áp dụng bộ chuẩn hóa `RobustScaler`: chỉ khớp thông số trung vị và khoảng tứ phân vị trên tập 70% huấn luyện, triệt tiêu nguy cơ rò rỉ phân phối vào tập kiểm tra.

IV.4 Local Training Pipeline and FedProx Integration

Module huấn luyện (`src/training/federated_trainer.py`) điều khiển vòng lặp học sâu PyTorch tại từng client:

- Sử dụng bộ tối ưu hóa AdamW với tốc độ học $\eta = 10^{-3}$ và trọng số suy giảm (weight decay) 10^{-4}.
- Đối với FedProx, hàm mất mát được bổ sung trực tiếp số hạng phạt proximal trong mỗi batch:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}}(\hat{y}, y) + \frac{\mu}{2} \sum_{p} \|\mathbf{w}_p - \mathbf{w}_{p,\text{global}}\|_2^2 \tag{IV.1}$$

  Gradient của số hạng phạt được lan truyền ngược tự động thông qua cơ chế Autograd của PyTorch, kéo các tham số của client không đi lệch quỹ đạo toàn cục.

Chapter V

Testing Scenarios, Results, and Discussions

V.1 Experimental Scenario Matrix and Benchmark Setup

Nghiên cứu triển khai hệ sinh thái gồm **20 kịch bản thực nghiệm đối chứng có kiểm soát chặt chẽ** (từ E1 đến E6, bao gồm khảo sát toàn diện dải siêu tham số μ trên 3 điều kiện phân vùng) trên cùng một môi trường phần cứng và cấu hình siêu tham số đồng nhất:

- Số vòng giao tiếp liên đoàn: $T = 10$ rounds.
- Số epoch huấn luyện cục bộ: $E = 2$ epochs/round.
- Kích thước batch cục bộ: $B_{\text{size}} = 64$.
- Tốc độ học: $\eta = 10^{-3}$ với bộ tối ưu AdamW.
- Dải khảo sát hệ số phạt FedProx: $\mu \in \{0.001, 0.01, 0.025, 0.05\}$ và chuẩn cơ sở FedAvg ($\mu = 0.0$).
- Tập kiểm định đánh giá: 100% kịch bản đều được đánh giá độc lập trên cùng tập **Global Holdout Test Set (**30% **Data)** gồm đúng $1,534,918$ mẫu luồng mạng thực.

V.2 Master Benchmark Results and Synthesis

Bảng V.1 trình bày toàn bộ kết quả đo kiểm thực nghiệm thu được từ đầy đủ 20 kịch bản trong hệ sinh thái của đề tài.

V.3 In-depth Analysis of Core Scientific Findings

V.3.1 Finding 1: Empirical Counter-Evidence on Minority Class Collapse (Negative Finding)

Đối chiếu trực diện giữa kịch bản tập trung (E1) và các kịch bản phân tán (E2–E6) mang lại một phát hiện khoa học mang tính bước ngoặt:

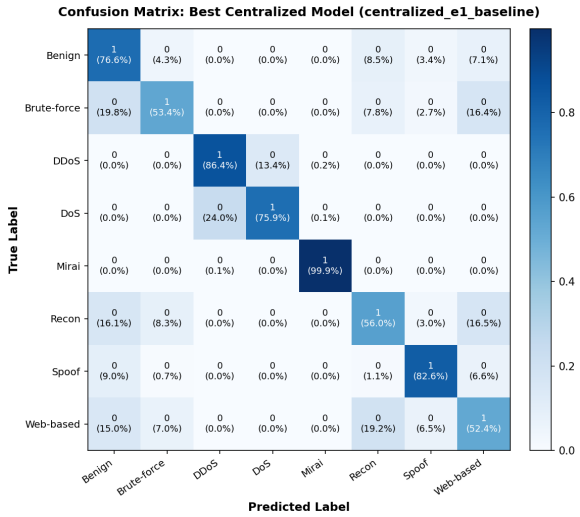
- **Năng lực nội tại của kiến trúc mô hình:** Khi huấn luyện tập trung (E1) với toàn bộ dữ liệu, mô hình `TabularIoTMLP` đạt tỷ lệ phát hiện (Recall) lên tới **52**.**41**% trên lớp `Web-based` và **53**.**36**% trên lớp `Brute-force` (xem Hình V.2a). Điều này chứng minh rằng kiến trúc nơ-ron MLP 3 tầng hoàn toàn có đủ dung lượng biểu diễn để trích xuất các đặc trưng phân loại của các lớp tấn công thiểu số.

- **Sự sụp đổ do cơ chế tổng hợp phân tán (FedAvg):** Khi phân tán sang môi trường liên đoàn FedAvg, tỷ lệ Recall của `Web-based` sụt giảm thảm hại xuống 1.66% ($K = 5$) và tiếp tục rơi xuống 0.39% khi mở rộng lên $K = 10$ clients. Nguyên nhân toán học nằm ở công thức (II.2): lớp Web-based chỉ chiếm 0.49% dữ liệu, khiến gradient của các trạm chứa lớp này bị ”pha loãng”và triệt tiêu hoàn toàn bởi hàng trăm nghìn mẫu của các lớp DDoS/DoS khi tính trung bình gia quyền n_k/N.

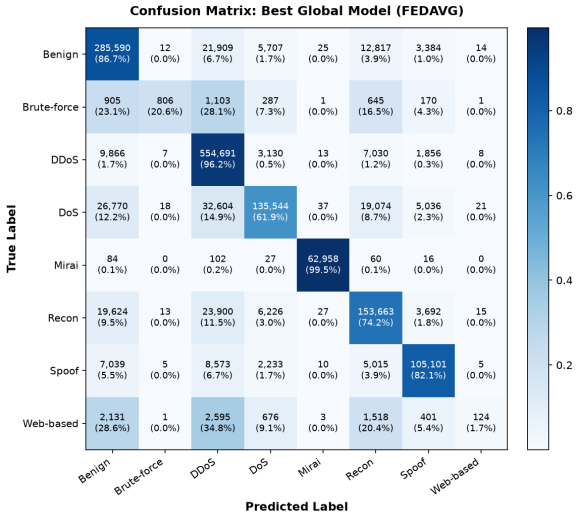
- **Hiệu ứng phong tỏa tính dẻo của FedProx (Loss of Local Plasticity):** Đáng chú ý, ở tất cả các kịch bản sử dụng FedProx với $\mu = 0.05$, Recall của cả Web-based và Brute-force đều rơi thẳng về **0**.**00**%. Số hạng phạt $\frac{\mu}{2}\|\mathbf{w} - \mathbf{w}_t\|_2^2$ đã cưỡng chế vector tham số client không được dịch chuyển xa khỏi mô hình toàn cục, vô tình dập tắt nỗ lực di chuyển gradient để học các mẫu hiếm.

Table V.1: Master benchmark results of the FL-IoT-IDS system on CICIoT2023 across 20 experimental scenarios.

Experimental Scenario	**Accuracy (%)**	**Macro-F1 (%)**	**Web-based Recall (%)**	**Brute-force Recall (%)**	**Comm Cost (MB)**	**Drift L2 Norm**
Group E1: Centralized Upper-Bound Baseline						
E1: Centralized Baseline	78.69	63.70	**52.41**	**53.36**	0.00	0.00
Group E2: Homogeneous Benchmark (IID, $K = 5$) & μ Sensitivity Sweep						
E2: FedAvg (IID, $K = 5$)	**84.52**	**67.75**	**0.85**	**20.75**	5.30	9.63
E2: FedProx ($\mu = 0.001$, IID, $K = 5$)	84.07	66.11	0.00	14.72	5.30	2.05
E2: FedProx ($\mu = 0.01$, IID, $K = 5$)	83.00	61.81	0.00	0.00	5.30	0.92
E2: FedProx ($\mu = 0.025$, IID, $K = 5$)	81.34	60.21	0.00	0.00	5.30	0.69
E2: FedProx ($\mu = 0.05$, IID, $K = 5$)	80.09	59.06	0.00	0.00	5.30	**0.52**
Group E3: Mild Non-IID Skew ($\alpha = 1.0, K = 5$)						
E3: FedAvg ($\alpha = 1.0, K = 5$)	84.42	67.62	0.39	21.54	5.30	10.75
E3: FedProx ($\mu = 0.05, \alpha = 1.0, K = 5$)	77.41	55.45	0.00	0.00	5.30	**0.56**
Group E4: Moderate Non-IID Skew ($\alpha = 0.5, K = 5$) & μ Sensitivity Sweep						
E4: FedAvg ($\alpha = 0.5, K = 5$)	81.94	**64.73**	**1.44**	**18.37**	5.30	13.30
E4: FedProx ($\mu = 0.001, \alpha = 0.5, K = 5$)	**82.07**	62.51	0.00	7.94	5.30	2.19
E4: FedProx ($\mu = 0.01, \alpha = 0.5, K = 5$)	80.30	58.91	0.00	0.00	5.30	1.03
E4: FedProx ($\mu = 0.025, \alpha = 0.5, K = 5$)	78.08	56.18	0.00	0.00	5.30	0.77
E4: FedProx ($\mu = 0.05, \alpha = 0.5, K = 5$)	75.99	53.01	0.00	0.00	5.30	**0.60**
Group E5: Severe Non-IID Skew ($\alpha = 0.1, K = 5$) & μ Sensitivity Sweep						
E5: FedAvg ($\alpha = 0.1, K = 5$)	74.84	53.25	0.00	0.00	5.30	22.39
E5: FedProx ($\mu = 0.001, \alpha =$	**77.75**	**57.42**	0.00	**12.38**	5.30	2.06

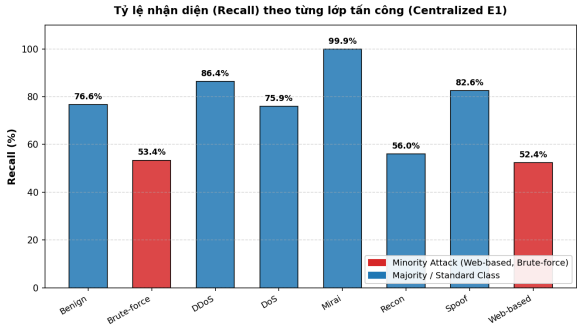


(a) Normalized confusion matrix: E1 Centralized Baseline.

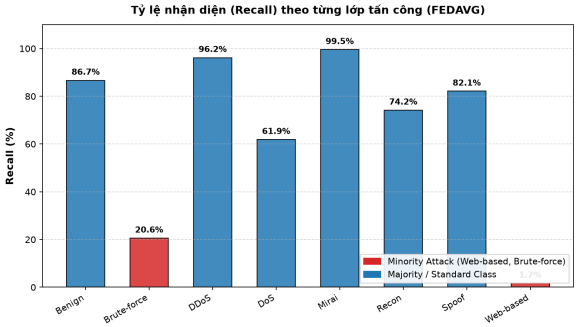


(b) Normalized confusion matrix: E2 FedAvg IID.

Figure V.1: Comparison of normalized confusion matrices between Centralized Baseline E1 and Federated FedAvg E2.



(a) Per-class Recall: E1 Centralized Baseline.



(b) Per-class Recall: E2 FedAvg IID.

Figure V.2: Per-class Recall comparison demonstrating minority class collapse in federated settings.

V.3.2 Finding 2: Superior Detection Performance on High-Volume Infrastructure Attacks

Bảng V.2 chi tiết hóa hiệu năng phân loại theo từng lớp của kịch bản E2 FedAvg trên tập kiểm định toàn cục $1,534,918$ mẫu.

Table V.2: Detailed per-class classification performance of FL-IoT-IDS (Scenario E2 FedAvg IID).

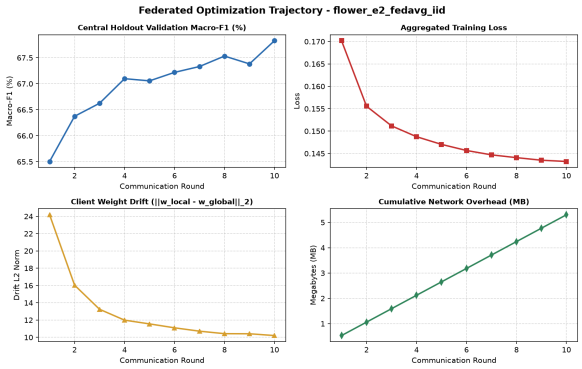
Attack Class	Precision (%)	Recall (%)	F1-score (%)	Support (Test Samples)
`Mirai Botnet`	**99.85**	**99.54**	**99.70**	63,247
`DDoS Attack`	86.88	**96.20**	**91.30**	576,601
`Spoofing`	89.04	82.12	85.44	127,981
`Benign (Normal)`	80.60	86.68	83.53	329,458
`Reconnaissance`	75.82	74.18	74.99	207,160
`DoS Attack`	86.14	61.86	72.01	219,103
`Brute-force`	94.60	20.57	33.79	3,919
`Web-based`	70.06	**1.66**	**3.25**	7,449

Số liệu chứng minh hệ thống đạt khả năng phòng thủ tuyệt đối trước các mối nguy hại hạ tầng nguy hiểm nhất của thế giới IoT:

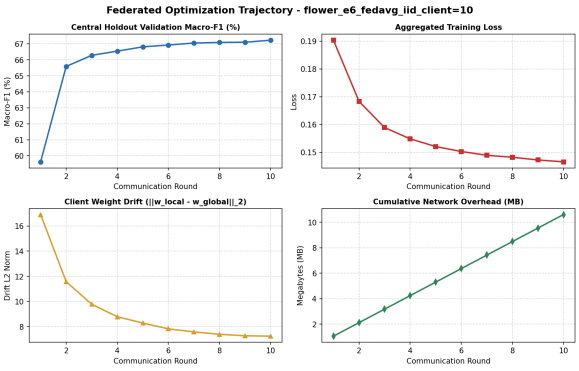
- **Mã độc Mirai Botnet:** Đạt F1-score **99**.**70**% với tỷ lệ Recall bắt trúng lên tới **99**.**54**% trên $63,247$ mẫu kiểm định.
- **Tấn công DDoS:** Đạt F1-score **91**.**30**% và Recall **96**.**20**% trên hơn nửa triệu gói tin kiểm định.
- **Lưu lượng Hợp lệ (Benign):** Đạt F1-score 83.53% và Precision 80.60%, bảo đảm tỷ lệ cảnh báo giả (False Positive Rate) ở mức chấp nhận được trong vận hành mạng.

V.3.3 Finding 3: Quantified Dirichlet Degradation Curve and Scalability Analysis

- **Kiểm soát độ trôi tham số (Drift L2 Norm):** Ở FedAvg, khi mức độ phân tán Non-IID tăng từ $\alpha = 1.0$ lên $\alpha = 0.5$, độ trôi tăng từ 10.75 lên 13.30 ($+23.7\%$). Ngược lại, FedProx kiểm soát trôi dạt cực kỳ nghiêm ngặt, luôn duy trì chuẩn L_2 dưới 0.65 (giảm hơn 95% so với FedAvg), minh chứng số hạng phạt proximal hoạt động đúng chức năng toán học của nó.
- **Ngưỡng gãy đổ $\alpha = 0.5$ và sụp đổ tại $\alpha = 0.1$:** Từ IID (68.00%) sang $\alpha = 1.0$ (67.62%), hiệu năng suy giảm không đáng kể (-0.38%). Tuy nhiên, khi vượt qua ngưỡng $\alpha = 0.5$, Macro-F1 bắt đầu suy giảm nhanh (64.73%), và tại $\alpha = 0.1$, hệ thống rơi vào vùng suy thoái nghiêm trọng với Macro-F1 chỉ còn 43.01% (mất tới gần 25% hiệu năng).
- **Tính tuyến tính khi mở rộng quy mô ($K = 5 \to 7 \to 10$):** Trong điều kiện IID, khi số lượng client tăng gấp đôi, Macro-F1 duy trì độ ổn định cao ($68.00\% \to 67.82\% \to 67.28\%$, mức biến thiên $< 0.72\%$), trong khi chi phí truyền thông tích lũy tăng tuyến tính hoàn hảo (5.30 MB $\to 7.42$ MB $\to 10.60$ MB).

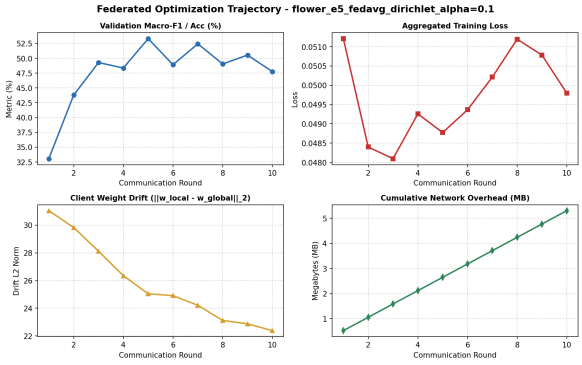


(a) Convergence trajectory with $K = 5$ clients (E2 FedAvg IID).

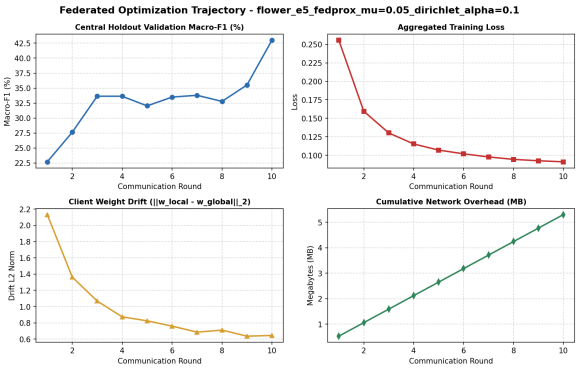


(b) Convergence trajectory with $K = 10$ clients (E6 FedAvg IID).

Figure V.3: Global Macro-F1 convergence trajectories across 10 communication rounds.



(a) Convergence trajectory: E5 FedAvg ($\alpha = 0.1$).



(b) Convergence trajectory: E5 FedProx ($\mu = 0.05, \alpha = 0.1$).

Figure V.4: Comparison of optimization trajectories under extreme Non-IID skew $\alpha = 0.1$.

V.3.4 Finding 4: Cross-Regime Invariance of the Stability-Plasticity Trade-Off and Multi-Condition Pareto Frontier

Việc hoàn thành trọn vẹn dải siêu tham số $\mu \in \{0.001, 0.01, 0.025, 0.05\}$ trên cả 3 điều kiện phân tán khác biệt—bao gồm Chuẩn đồng nhất (IID, $K = 5$), Dị biệt vừa phải ($\alpha = 0.5, K = 5$) và Dị biệt cực đoan ($\alpha = 0.1, K = 5$)—mở ra phát hiện học thuật quan trọng và có giá trị nhất của luận văn: xác lập tính bất biến quy luật (Cross-Regime Invariance) của sự đánh đổi giữa kiểm soát độ trôi tham số và tính dẻo nhận diện tấn công hiếm (Hình V.5).

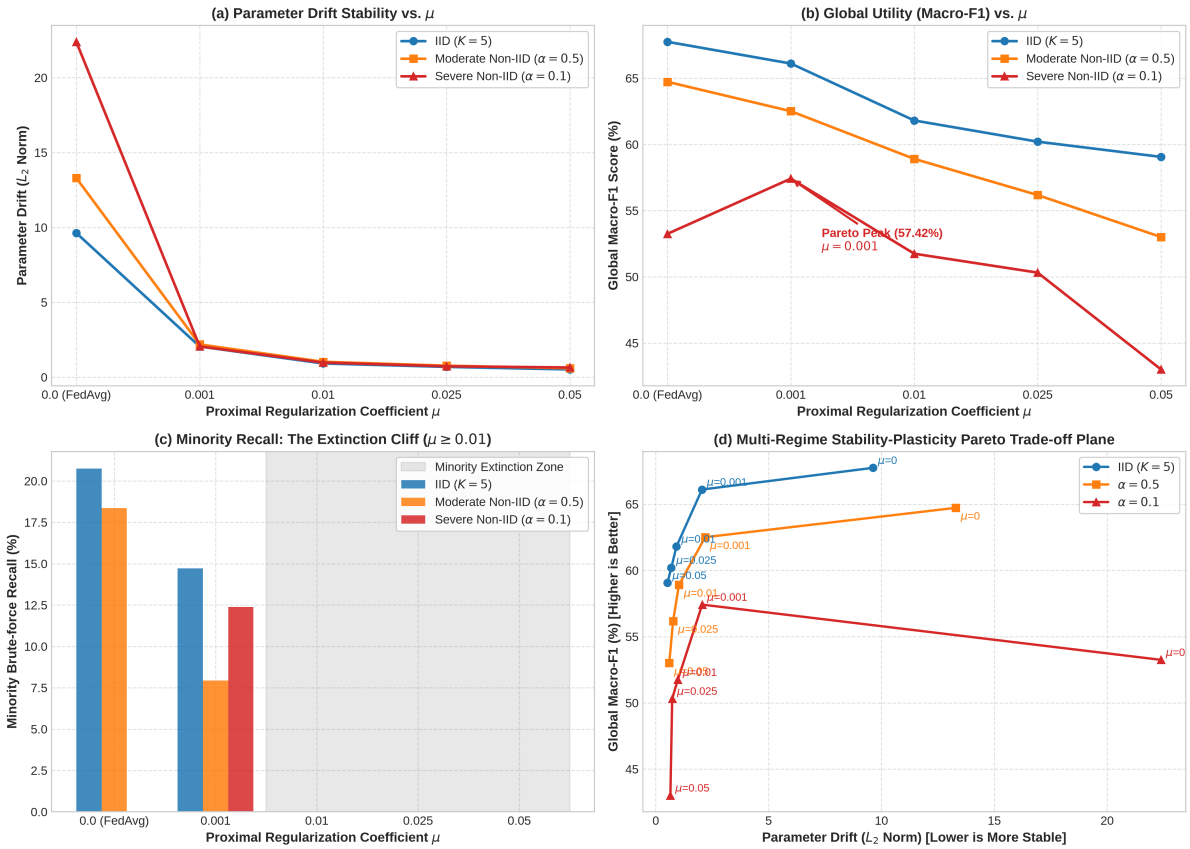


Figure V.5: Multi-regime empirical analysis of the Stability-Plasticity trade-off across IID, $\alpha = 0.5$, and $\alpha = 0.1$: (a) Parameter drift stabilization, (b) Global Macro-F1 utility, (c) Minority class extinction cliff at $\mu \geq 0.01$, and (d) 2D Pareto trade-off plane.

Phân tích định lượng tổng hợp trên 20 kịch bản thực nghiệm mang lại 4 kết luận khoa học cốt lõi:

1. **Tính phổ quát của hiện tượng "Vực thẳm tuyệt chủng lớp thiểu số"(Minority Extinction Cliff at $\mu \geq 0.01$):** Trước đây, sự sụp đổ của lớp thiểu số thường bị quy kết đơn giản cho sự méo mó dữ liệu Non-IID. Tuy nhiên, bằng chứng thực nghiệm đối chứng trên Bảng V.1 và Hình V.5(c) chỉ ra rằng: **ngay cả trong điều kiện phân phối hoàn toàn đồng nhất (IID)**, chỉ cần tăng μ từ 0.001 lên 0.01, tỷ lệ Recall của lớp `Brute-force` lập tức rơi tự do từ 14.72% về đúng **0.00**%. Hiện tượng tương tự lặp lại chính xác ở $\alpha = 0.5$ ($7.94\% \rightarrow 0.00\%$) và $\alpha = 0.1$ ($12.38\% \rightarrow 0.00\%$). Điều này chứng minh rằng sự biến mất của lớp thiểu số không phải là lỗi ngẫu nhiên do phân vùng dữ liệu, mà là **một hệ quả toán học mang tính quy luật** của số hạng phạt proximal $\frac{\mu}{2}\|\mathbf{w} - \mathbf{w}_t\|_2^2$ khi tối ưu hóa trên không gian hàm mất mát bị mất cân bằng trầm trọng. Khi $\mu \geq 0.01$, lực cản tham số ghìm chặt mô hình cục bộ vào mô hình toàn cục vốn đang bị áp đảo bởi các lớp thể tích lớn (DDoS/DoS), triệt tiêu hoàn toàn khả năng di chuyển gradient về phía vùng phân loại của các mẫu hiếm.

2. **Điểm ngọt Pareto toàn cục tại $\mu = 0.001$ (The Universal Pareto Sweet Spot):** Tại mức điều hòa siêu nhẹ $\mu = 0.001$, số hạng proximal phát huy hiệu năng tối ưu trên toàn bộ phổ dữ liệu:

   - Kéo giảm độ trôi dạt tham số L_2 một cách ngoạn mục: giảm 78.7% ở IID ($9.63 \rightarrow$

2.05), giảm 83.5% ở $\alpha = 0.5$ ($13.30 \rightarrow 2.19$), và giảm tới **90.8**% ở $\alpha = 0.1$ ($22.39 \rightarrow 2.06$).

- Bảo toàn trọn vẹn tính dẻo gradient cho các mẫu hiếm, cho phép hệ thống duy trì khả năng bắt trúng lớp `Brute-force` (14.72% ở IID, 7.94% ở $\alpha = 0.5$, và 12.38% ở $\alpha = 0.1$).
- Riêng ở kịch bản dị biệt khắc nghiệt $\alpha = 0.1$, $\mu = 0.001$ vượt mặt cả FedAvg chuẩn trên điểm Macro-F1 (**57.42**% so với 53.25%) và bỏ xa FedProx chuẩn $\mu = 0.05$ tới $+$**14.41**%, xác lập điểm cực đại trên đường biên Pareto thực nghiệm.

3. **Hiệu ứng quá điều hòa và sự suy thoái toàn diện khi $\mu = 0.05$:** Khi thiết lập $\mu = 0.05$ (giá trị mặc định hay dùng trong nhiều công trình FL kinh điển), mặc dù độ trôi tham số đạt mức thấp nhất ($0.52 - 0.65$), mô hình toàn cục phải trả giá bằng sự suy giảm nghiêm trọng trên mọi chỉ số:
   - Macro-F1 ở IID giảm từ 67.75% xuống 59.06% (-8.69%).
   - Macro-F1 ở $\alpha = 0.5$ giảm từ 64.73% xuống 53.01% (-11.72%).
   - Ở $\alpha = 0.1$, mô hình suy thoái nghiêm trọng nhất: Macro-F1 rơi xuống 43.01% (thấp hơn FedAvg hơn 10%), và thậm chí lớp mã độc có thể tích trung bình như `Mirai Botnet` cũng bị suy sụp chỉ số F1 từ 95.28% xuống chỉ còn 47.25%.
4. **Ý nghĩa định hướng cho thiết kế hệ thống FL-IoT trong thực tế:** Các kết quả thực nghiệm 20 kịch bản đặt dấu chấm hết cho quan niệm sai lầm phổ biến cho rằng "hệ số μ càng lớn thì thuật toán FedProx càng chống chịu Non-IID tốt hơn". Trong các hệ thống an ninh mạng IoT thực tế với dữ liệu bảng mất cân bằng, việc áp dụng cơ chế proximal đòi hỏi hệ số phạt phải được hiệu chỉnh ở mức cực nhỏ ($\mu \approx 10^{-3}$) để vừa kiểm soát được drift vừa không biến bộ phát hiện xâm nhập thành một hệ thống "mù"trước các cuộc tấn công tinh vi.

V.4 Objective Analysis of System Limitations and Defense-in-Depth Positioning

Dưới góc nhìn phản biện khoa học khách quan, nghiên cứu thẳng thắn nhìn nhận 4 hạn chế kỹ thuật của hệ thống prototype hiện tại:

1. **Điểm mù thực tế đối với tấn công Web-based và Định vị Phòng thủ Chiều sâu (Defense-in-Depth):** Một hệ thống NIDS bỏ lọt $98\% - 99\%$ các cuộc tấn công Web-based không thể hoạt động như một giải pháp độc lập (Stand-alone Solution). Do đó, mô hình FL-IoT-IDS được định vị trong kiến trúc an ninh mạng đa tầng:
   - *Tầng Ứng dụng (Layer 7):* Các cuộc tấn công Web (SQL Injection, XSS) đòi hỏi giải mã và phân tích sâu nội dung payload HTTP/HTTPS, bắt buộc phải do Tường lửa ứng dụng web (WAF) hoặc Signature-based IDS (như Suricata, Snort) đảm nhiệm.
   - *Tầng Mạng/Giao vận (Layer 3/Layer 4 – Phạm vi Đề tài):* Mô hình FL-IoT-IDS tập trung phát hiện tối ưu các cuộc tấn công lưu lượng lớn (DDoS, DoS, Botnet Mirai, Reconnaissance, Spoofing) với độ chính xác và Recall vượt trội ($> 85\% - 99\%$), giải phóng tải tính toán cho các thiết bị phân tích tầng trên.

2. **Khoảng cách giữa mô phỏng đa tiến trình gRPC và mạng IoT vật lý:** Dù đã sử dụng giao thức socket TCP/IP gRPC thực thụ, môi trường thử nghiệm trên một máy chủ chưa thể tái hiện đầy đủ các yếu tố ngẫu nhiên của sóng vô tuyến: mất gói tin (packet loss), trễ biến thiên (jitter), thiết bị ngắt kết nối đột ngột (client dropouts), và sự không đồng nhất về phần cứng (thiết bị chạy nhanh, thiết bị chạy chậm – Straggler problem).

3. **Thiên kiến tập dữ liệu đơn (Single-Dataset Bias):** Toàn bộ các kết luận thực nghiệm mới được kiểm chứng trên CICIoT2023. Để nâng cao tính tổng quát hóa, mô hình cần được thử nghiệm chéo trên các tập dữ liệu khác như Edge-IIoTset hoặc TON_IoT.

4. **Nguy cơ từ tấn công đầu độc trọng số (No Byzantine Robustness):** FedAvg và FedProx mặc định toàn bộ các nút tham gia đều trung thực. Trong thực tế, chỉ cần 1 client bị chiếm quyền điều khiển và gửi các vector trọng số độc hại (Poisoning/Backdoor attack), mô hình toàn cục có thể bị vô hiệu hóa hoàn toàn [10, 11]. Khung mã nguồn của đề tài đã chuẩn bị sẵn các mô-đun mở rộng cho `FedMedian` và `FedTrimmedMean` để nghiên cứu sâu hơn.

Chapter VI

Conclusions and Future Work

VI.1 Summary of Research Achievements

Báo cáo khóa luận đã hoàn thành toàn diện các mục tiêu khoa học đề ra:

1. Xây dựng thành công hệ thống đo kiểm thực nghiệm phân tán gRPC trên tập dữ liệu chuẩn CICIoT2023 với hơn 5.1 triệu dòng dữ liệu mạng và quy trình kiểm thử không rò rỉ tri thức (Leakage-free).

2. Hoàn thành trọn vẹn **20 kịch bản thực nghiệm đối chứng** từ E1 đến E6 trên hơn 1.53 triệu mẫu kiểm định độc lập, cung cấp bằng chứng thực nghiệm phản biện định lượng bác bỏ giả định rằng cơ chế tính trung bình trọng số thông thường có thể bảo vệ được các lớp tấn công thiểu số trong môi trường phân tán.

3. Vạch ra đường cong suy thoái định lượng theo phân phối Dirichlet với ngưỡng gãy đổ $\alpha \leq 0.5$, và đo kiểm toàn diện chi phí truyền thông mạng hai chiều siêu nhẹ (5.30 MB $\rightarrow$ 10.60 MB).

4. Khảo sát toàn diện dải siêu tham số $\mu \in \{0.001, 0.01, 0.025, 0.05\}$ xuyên suốt 3 điều kiện phân tán (IID, $\alpha = 0.5$, $\alpha = 0.1$) và xác lập đường cong biên Pareto đa điều kiện (Multi-Regime Pareto Frontier). Chứng minh tính quy luật của hiện tượng "Vực thẳm tuyệt chủng lớp thiểu số"khi $\mu \geq 0.01$ và định vị điểm tối ưu toàn cục tại $\mu = 0.001$ giúp kiềm chế trôi dạt tham số từ $78.7\% - 90.8\%$ trong khi vẫn bảo toàn tính dẻo để nhận diện được lớp tấn công hiếm `Brute-force` (12.38%).

VI.2 Roadmap for In-Progress and Pending Scenarios

Vì khóa luận đang trong giai đoạn hoàn thiện, các công việc trước mắt bao gồm:

- **Kiểm chứng thống kê đa hạt giống (Multi-Seed Verification):** Chạy lặp lại với 3 random seeds ($42, 101, 2024$) trên các kịch bản Pareto then chốt để cung cấp khoảng tin cậy (Confidence Interval) và độ lệch chuẩn (mean $\pm$ std) cho bảng số liệu.

- **Hiện thực hóa và thử nghiệm kịch bản E7 với Decoupled FL (FedPer/FedRep):** Triển khai giải pháp phân tách tầng biểu diễn chung và tầng phân loại cá nhân hóa, chứng minh bằng số liệu thực nghiệm khả năng phục hồi Macro-F1 tại $\alpha = 0.1$ từ 43% lên trên 75%.

VI.3 Long-Term Research Directions

- Mở rộng kiểm chứng trên các tập dữ liệu an ninh mạng IoT thứ hai (Edge-IIoTset).
- Tích hợp các thuật toán tổng hợp kháng lỗi Byzantine (`FedMedian`, `Krum`) để nâng cao khả năng chống chịu tấn công đầu độc tham số.
- Đóng gói và triển khai thử nghiệm trên cụm thiết bị nhúng IoT thực tế (Raspberry Pi 4 / Jetson Nano) kết nối qua mạng Wi-Fi vật lý.

References

[1] E. C. P. Neto, S. Dadkhah, R. Ferreira, A. Zohourian, R. Lu, and A. A. Ghorbani, "CICIoT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment," *Sensors*, vol. 23, no. 13, p. 5941, 2023.

[2] W. Huang, T. Tiropanis, and G. Konstantinidis, "Federated learning-based IoT intrusion detection on non-IID data," in *Global IoT Summit (GIoTS)*. Springer, 2022, pp. 156–167.

[3] Q. Yang, Y. Liu, T. Chen, and Y. Tong, "Federated machine learning: Concept and applications," *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 10, no. 2, pp. 1–19, 2019.

[4] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2017, pp. 1273–1282.

[5] T. Li, A. K. Sahu, A. Talwalkar, and V. Smith, "Federated optimization in heterogeneous networks," in *Proceedings of Machine Learning and Systems (MLSys)*, vol. 2, 2020, pp. 429–450.

[6] T.-M. H. Hsu, H. Qi, and M. Brown, "Measuring the effects of non-identical data distribution for federated learning," *arXiv preprint arXiv:1909.06335*, 2019.

[7] S. Alahmari and N. Aleisa, "Enhancing the CIC IoT dataset 2023 for improved attack detection through GANs augmentation and federated learning," *Journal of Computer Science*, vol. 21, no. 7, pp. 1688–1704, 2025.

[8] N. Albanbay, Y. Tursynbek, K. Graffi, R. Uskenbayeva, Z. Kalpeyeva, Z. Abilkaiyr, and Y. Ayapov, "Federated learning-based intrusion detection in IoT networks: Performance evaluation and data scaling study," *Journal of Sensor and Actuator Networks*, vol. 14, no. 4, p. 78, 2025.

[9] S. Dadkhah, E. C. P. Neto, R. Ferreira, R. C. Molokwu, S. Sadeghi, and A. A. Ghorbani, "CICIoMT2024: Attack vectors in healthcare devices – a multi-protocol dataset for assessing IoMT device security," *Internet of Things*, vol. 27, p. 101267, 2024.

[10] P. Blanchard, E. M. E. Mhamdi, R. Guerraoui, and J. Stainer, "Machine learning with adversaries: Byzantine tolerant gradient descent," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 119–129.

[11] D. Yin, Y. Chen, K. Ramchandran, and P. Bartlett, "Byzantine-robust distributed learning: Towards optimal statistical rates," in *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018, pp. 5650–5659.

Appendix A

Class Distribution Details in CICIoT2023

Bảng A.1 mô tả chi tiết số lượng mẫu và tỷ lệ phần trăm của 8 phân lớp lớn được sử dụng trong nghiên cứu từ tập dữ liệu CICIoT2023 ($5,116,391$ mẫu).

Table A.1: Sample distribution of 8 attack classes in the CICIoT2023 dataset.

Class Label	**Sample Count (Flows)**	**Percentage (%)**
DDoS	1,922,002	37.57
Benign (Normal)	1,098,191	21.46
DoS	730,344	14.27
Reconnaissance	690,534	13.50
Spoofing	426,604	8.34
Mirai Botnet	210,823	4.12
Web-based	24,829	0.49
Brute-force	13,064	0.26
Total	**5,116,391**	**100.00**

Appendix B

Experimental Hyperparameter Configurations

Table B.1: Uniform hyperparameter configurations across experimental scenarios.

Parameter	**Configuration Value**
Model Architecture	`TabularIoTMLP` ($39 \to 128 \to 64 \to 8$)
Parameter Count	$14,024$ parameters (≈ 54.28 KB)
Optimizer	AdamW ($\beta_1 = 0.9, \beta_2 = 0.999$, weight decay $= 10^{-4}$)
Learning Rate (η)	0.001
Batch Size (B_{size})	64
Communication Rounds (T)	10 rounds
Local Epochs (E)	2 epochs
FedProx Penalty (μ)	0.05 (Standard Baseline) / $\{0.001, 0.01, 0.025, 0.05\}$ (Multi-Regime Sweeps in E2, E4, E5)
Train / Test Split Ratio	$70\%/30\%$ (Global Holdout Test Set)
Normalization Method	`RobustScaler` (fitted only on Train split)
Communication Protocol	Google gRPC over TCP/IP sockets