ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG

BÁO CÁO TIẾN ĐỘ & KẾT QUẢ THỰC NGHIỆM KHÓA LUẬN TỐT NGHIỆP

XÂY DỰNG VÀ ĐÁNH GIÁ PROTOTYPE HỆ THỐNG PHÁT HIỆN XÂM NHẬP IOT SỬ DỤNG FEDERATED LEARNING TRONG MÔI TRƯỜNG DỮ LIỆU NON-IID

Sinh viên thực hiện: Nguyễn Việt Kỳ Quân – 23521267
Cán bộ hướng dẫn: PGS. TS. Lê Trung Quân

Chuyên ngành: Mạng máy tính và An toàn thông tin

Ngày 30 tháng 10 năm 2026

Tóm tắt nội dung

Sự phát triển mạnh mẽ của Internet vạn vật (IoT) đã mở rộng đáng kể bề mặt tấn công mạng, đòi hỏi các giải pháp Phát hiện Xâm nhập Mạng (NIDS) hiệu quả và bảo toàn quyền riêng tư. Học liên đoàn (Federated Learning – FL) nổi lên như một hướng tiếp cận đầy triển vọng cho phép huấn luyện mô hình phân tán mà không cần tập trung hóa dữ liệu thô. Tuy nhiên, sự phi đồng nhất về mặt thống kê (Non-IID) và hiện tượng mất cân bằng lớp cực đoan giữa các trạm mạng IoT biên đặt ra rào cản kỹ thuật nghiêm trọng đối với quá trình hội tụ mô hình.

Báo cáo này trình bày thiết kế, hiện thực nguyên mẫu (prototype) và đánh giá thực nghiệm đa chiều của hệ thống FL-IoT-IDS trên tập dữ liệu chuẩn mới CICIoT2023. Hệ thống được triển khai trên nền tảng giao thức Flower gRPC sockets với mô hình Tabular MLP nhỏ gọn ($14,024$ tham số, ≈ 54.28 KB). Thông qua chuỗi 10 kịch bản thực nghiệm đối chứng có kiểm soát (từ E1 đến E6) bao gồm chuẩn tập trung (Centralized Baseline), dữ liệu IID, và phân phối Dirichlet Non-IID ($\alpha \in \{1.0, 0.5, 0.1\}$), nghiên cứu cung cấp các bằng chứng thực nghiệm phản biện định lượng mang giá trị học thuật cao:

1. **Phát hiện phản nghiệm (Empirical Counter-Evidence):** Trong khi mô hình tập trung (E1) đạt tỷ lệ phát hiện (Recall) lớp `Web-based` là 52.41% và `Brute-force` là 53.36%, việc phân tán qua FedAvg làm tỷ lệ này sụp đổ xuống 1.66% ($K = 5$) và 0.39% ($K = 10$), và bị dập tắt hoàn toàn về 0.00% ở FedProx do cơ chế phạt proximal ghìm chết gradient. Điều này chứng minh sự sụp đổ lớp thiểu số không phải do khiếm khuyết kiến trúc MLP mà do hạn chế toán học của cơ chế tổng hợp tham số phân tán.
2. **Hiệu năng vượt trội ở các lớp lưu lượng thể tích lớn:** Hệ thống đạt khả năng phát hiện xuất sắc trên các cuộc tấn công hạ tầng nguy hiểm: Mirai Botnet đạt F1-score 98.78% (Recall 99.88%), DDoS đạt F1-score 88.38% (Precision 90.45%), và Spoofing đạt F1-score 83.98%.
3. **Vạch ra đường cong suy thoái Dirichlet định lượng:** Xác định ngưỡng gãy đổ $\alpha \leq 0.5$ và hiện tượng nhiễu loạn triệt tiêu tại $\alpha = 0.1$ (Macro-F1 sụt giảm từ 68.00% xuống 43.01%).
4. **Đề xuất giải pháp thuật toán đột phá:** Xây dựng cơ sở lý thuyết cho kiến trúc Decoupled Federated Learning (FedPer/FedRep) nhằm tách biệt tầng biểu diễn đặc trưng và tầng phân loại cá nhân hóa, mở đường cho việc khắc phục triệt để sự suy thoái Non-IID cực đoan.

Từ khóa: Học liên đoàn, Phát hiện xâm nhập IoT, Non-IID, Phân phối Dirichlet, FedAvg, FedProx, Decoupled FL, CICIoT2023, Flower gRPC.

Mục lục

1 Gii thiu và t vn **4**
- 1.1 Bi cnh và ng lc Nghiên cu . . . 4
- 1.2 Các Thách thc Ct lõi ca Mng IoT . . . 4
- 1.3 Mc tiêu và nh v óng góp ca tài . . . 5

2 C s Lý thuyt và Tng quan Nghiên cu Liên quan **5**
- 2.1 Tp D liu Chun CICIoT2023 . . . 5
- 2.2 Thut toán FedAvg và Thách thc Non-IID . . . 5
- 2.3 Thut toán FedProx và iu hòa Khong cách . . . 6
- 2.4 Mô hình hóa Non-IID bng Phân phi Dirichlet . . . 6
- 2.5 i sánh vi các Công trình Công b Gn ây (2024 – 2026) . . . 6

3 Thit k Kin trúc H thng Prototype FL-IoT-IDS **8**
- 3.1 Tng quan Kin trúc 4 Lp (The 4-Layer Architecture) . . . 8
- 3.2 Công thc c lng Chi phí Truyn thông . . . 8

4 Kt qu Thc nghim và Phân tích Chuyên sâu **9**
- 4.1 Thit lp Môi trng và Ma trn Benchmark . . . 9
- 4.2 Bng Tng hp Kt qu Thc nghim Master Benchmark . . . 9
- 4.3 Phân tích Ba Phát hin Khoa hc Thc cht . . . 9
  - 4.3.1 Phát hin 1: Bng chng Thc nghim Phn bin v Gii hn Nhn din Lp Thiu s (Negative Finding) . . . 9
  - 4.3.2 Phát hin 2: Nng lc Vt tri i vi các Lp Tn công H tng Th tích Ln . . . 10
  - 4.3.3 Phát hin 3: ng cong Suy thoái nh lng Dirichlet và Tính Bn vng M rng 11

5 Tho lun, Hn ch và xut Hng i t phá **11**
- 5.1 Nhìn nhn Khách quan v các Hn ch K thut . . . 11
- 5.2 Ba xut Thut toán Nâng tm Giá tr Khoa hc (Algorithmic Proposals) . . . 12
  - 5.2.1 xut 1 (Khuyên dùng): Decoupled Federated Learning (FedPer/FedRep) cho IoT-IDS . . . 12
  - 5.2.2 xut 2: Pht Proximal Thích ng theo Entropy (μ-Adaptive FedProx) 12
  - 5.2.3 xut 3: Tng hp Nhn bit Mt cân bng (Imbalance-Aware Aggregation) 13
- 5.3 K hoch Hoàn thin Khóa lun và Bo v . . . 13

1 Giới thiệu và Đặt vấn đề

1.1 Bối cảnh và Động lực Nghiên cứu

Sự bùng nổ của các thiết bị Internet of Things (IoT) đã tạo ra một hệ sinh thái mạng phức tạp với hàng tỷ kết nối thông minh. Mặc dù mang lại tiện ích to lớn, phần lớn các thiết bị IoT biên (Edge IoT) đều có tài nguyên tính toán hạn chế, khả năng bảo mật yếu và thường xuyên trở thành mục tiêu của các chiến dịch tấn công diện rộng như từ chối dịch vụ phân tán (DDoS/DoS), mạng máy tính ma Mirai, hay dò quét mật khẩu (Brute-force) [1]. Để bảo vệ hạ tầng mạng IoT, các Hệ thống Phát hiện Xâm nhập Mạng (NIDS) ứng dụng Học máy (ML) và Học sâu (DL) đóng vai trò then chốt [2].

Trong mô hình học máy tập trung truyền thống (Centralized ML), toàn bộ lưu lượng mạng từ các thiết bị phân tán bắt buộc phải gửi về một máy chủ trung tâm để huấn luyện. Cách tiếp cận này bộc lộ hai yếu điểm chí mạng:

- **Vi phạm quyền riêng tư và quy định dữ liệu:** Lưu lượng mạng biên chứa thông tin định danh, cấu hình thiết bị và hành vi người dùng nhạy cảm; việc truyền tải dữ liệu thô vi phạm các tiêu chuẩn an toàn thông tin hiện đại (GDPR, ISO/IEC 27701) [3].
- **Nghẽn cổ chai băng thông truyền thông:** Hàng triệu thiết bị IoT liên tục truyền hàng terabyte dữ liệu luồng mạng (network flows) về trung tâm sẽ gây tắc nghẽn đường truyền đường dài và quá tải hạ tầng mạng lõi.

1.2 Các Thách thức Cốt lõi của Mạng IoT

Học liên đoàn (Federated Learning – FL) do McMahan et al. [4] đề xuất đã mở ra hướng đi mới: các trạm biên tự huấn luyện mô hình trên dữ liệu cục bộ và chỉ chia sẻ các tham số trọng số ($\mathbf{w}$) về máy chủ điều phối. Tuy nhiên, việc áp dụng FL vào bài toán an ninh mạng IoT gặp phải ba rào cản kỹ thuật nghiêm trọng:

1. **Dữ liệu phi đồng nhất (Non-IID Data Heterogeneity):** Trong thế giới thực, các trạm IoT biên quan sát lưu lượng mạng rất khác biệt tùy thuộc vào vị trí vật lý và chức năng thiết bị. Sự khác biệt phân phối nhãn dẫn đến hiện tượng trôi dạt trọng số cục bộ (*Client Drift*), khiến thuật toán Federated Averaging (FedAvg) suy thoái nặng nề hoặc không thể hội tụ [5, 6].
2. **Mất cân bằng lớp cấu trúc cực đoan (Severe Structural Class Imbalance):** Trong các tập dữ liệu lưu lượng mạng như CICIoT2023, các cuộc tấn công DDoS/DoS chiếm hơn 70% lưu lượng, trong khi các cuộc tấn công tinh vi nguy hiểm như Web-based (SQL Injection, XSS) hay Brute-force chỉ chiếm dưới 0.5%. Khi huấn luyện phân tán, các lớp đa số áp đảo hoàn toàn tín hiệu gradient, khiến mô hình gần như mất khả năng nhận diện các mối đe dọa thiểu số [7].
3. **Giới hạn tài nguyên phần cứng thiết bị biên (Resource Constraints):** Các gateway biên chỉ sở hữu năng lực CPU khiêm tốn và bộ nhớ hạn hẹp, không thể gánh vác các kiến trúc học sâu cồng kềnh (CNN-LSTM, Transformer) vốn đòi hỏi hàng chục megabytes payload cho mỗi vòng giao tiếp [8].

1.3 Mục tiêu và Định vị Đóng góp của Đề tài

Bám sát định hướng của một nghiên cứu thực nghiệm chuẩn mực, đề tài không tự xưng phát minh lý thuyết toán học vi mô xa rời thực tế, mà tập trung vào tính **hiện thực hóa kỹ thuật hệ thống** và **đo kiểm thực nghiệm có đối chứng khoa học (Empirical Benchmarking & System Prototype)** nhằm cung cấp ba đóng góp cốt lõi:

- **Xây dựng hoàn chỉnh Prototype FL-IoT-IDS:** Hiện thực hóa kiến trúc 4 lớp dựa trên framework Flower [9] giao tiếp qua socket TCP/IP gRPC thực thụ, sử dụng mô hình Tabular MLP nhỏ gọn ($14,024$ tham số, ≈ 54.28 KB) vận hành tối ưu trên CPU thiết bị biên, triệt tiêu triệt để các lỗi hệ thống Linux pipe buffer deadlock và GPU OOM.
- **Phát hiện thực nghiệm phản biện (Negative Finding):** Cung cấp bằng chứng định lượng đanh thép đối chứng giữa Centralized (E1) và FL (E2–E6), chứng minh cơ chế tổng hợp gia quyền thô n_k/N và số hạng điều hòa FedProx là nguyên nhân trực tiếp làm sụp đổ hoàn toàn khả năng phát hiện lớp thiểu số, bác bỏ giả định rằng Focal Loss/Class Weights cục bộ có thể giải quyết bài toán này.
- **Ma trận đối sánh đa chiều chuẩn mực & Đề xuất giải pháp cải tiến:** Thiết lập chuỗi kịch bản có kiểm soát từ E1 đến E6, vạch ra đường cong suy thoái định lượng theo hệ số Dirichlet $\alpha \in \{1.0, 0.5, 0.1\}$ và đánh giá chi phí truyền thông khi mở rộng quy mô $K \in \{5, 7, 10\}$ trạm biên; đồng thời đề xuất kiến trúc Decoupled Federated Learning nhằm nâng tầm giá trị khoa học cho công trình.

2 Cơ sở Lý thuyết và Tổng quan Nghiên cứu Liên quan

2.1 Tập Dữ liệu Chuẩn CICIoT2023

Tập dữ liệu CICIoT2023 [1] được thu thập tại Viện An ninh mạng Canada (CIC), mô phỏng môi trường mạng IoT quy mô lớn với 105 thiết bị phần cứng thật. Bộ dữ liệu chứa hơn 47 triệu bản ghi lưu lượng mạng flow-based với 39 đặc trưng số (statistical network flow features) và 33 phân loại tấn công được gom nhóm thành 8 lớp chính: *Benign, Brute-force, DDoS, DoS, Mirai, Reconnaissance, Spoofing*, và *Web-based*. CICIoT2023 phản ánh chính xác sự mất cân bằng thực tế của lưu lượng mạng IoT hiện đại với tỷ lệ mất cân bằng (imbalance ratio) lên tới 147.11 : 1.

2.2 Thuật toán FedAvg và Thách thức Non-IID

Thuật toán Federated Averaging (FedAvg) [4] thực hiện tổng hợp tham số mô hình toàn cục sau mỗi round t dựa trên tỷ lệ số lượng mẫu dữ liệu cục bộ n_k của K trạm biên tham gia:

$$\mathbf{w}_{t+1} = \sum_{k=1}^{K} \frac{n_k}{N} \mathbf{w}_{t+1}^{(k)} \quad \text{với} \quad N = \sum_{k=1}^{K} n_k \tag{1}$$

Trong môi trường IID, FedAvg hội tụ nhanh chóng. Tuy nhiên, khi dữ liệu phân tán bị lệch phân phối (Non-IID), mục tiêu tối ưu cục bộ $F_k(\mathbf{w})$ của từng client bị phân kỳ so với

mục tiêu toàn cục $F(\mathbf{w})$. Khoảng cách giữa các vector nghiệm cục bộ tạo ra hiện tượng trôi dạt tham số (*Client Drift*):

$$\Delta \mathbf{w}^{(k)} = \|\mathbf{w}_{\text{local}}^{(k)} - \mathbf{w}_{\text{global}}^{(t)}\|_2 = \sqrt{\sum_{l} \|\mathbf{w}_{\text{local}}^{(k,l)} - \mathbf{w}_{\text{global}}^{(t,l)}\|_2^2} \tag{2}$$

2.3 Thuật toán FedProx và Điều hòa Khoảng cách

Để đối phó với hiện tượng trôi dạt tham số do Non-IID, Li et al. [5] đề xuất thuật toán FedProx, bổ sung một số hạng phạt điều hòa (proximal term) vào hàm mất mát cục bộ của mỗi client:

$$\min_{\mathbf{w}} h_k(\mathbf{w}; \mathbf{w}_t) = F_k(\mathbf{w}) + \frac{\mu}{2}\|\mathbf{w} - \mathbf{w}_t\|_2^2 \tag{3}$$

Trong đó $\mu \geq 0$ là hệ số điều hòa. Thành phần phạt $\frac{\mu}{2}\|\mathbf{w} - \mathbf{w}_t\|_2^2$ có tác dụng "buộc dây"(anchor) vector trọng số của client không bị trôi dạt quá xa khỏi mô hình toàn cục $\mathbf{w}_t$, giúp quá trình hội tụ ổn định hơn khi dữ liệu giữa các client có sự dị biệt lớn.

2.4 Mô hình hóa Non-IID bằng Phân phối Dirichlet

Theo phương pháp luận chuẩn của Hsu et al. [6], tính phi đồng nhất về nhãn được mô phỏng thông qua phân phối Dirichlet:

$$\mathbf{p}_c \sim \text{Dir}(\alpha \cdot \mathbf{1}_K) \tag{4}$$

Trong đó $\mathbf{p}_c$ là vector xác suất phân bổ mẫu của lớp tấn công c cho K client, và $\alpha > 0$ là tham số tập trung (concentration parameter). Khi $\alpha \to \infty$, phân phối tiến về IID; khi $\alpha \to 0$, dữ liệu bị phân mảnh cực đoan, mỗi trạm biên chỉ chứa một vài lớp duy nhất.

2.5 Đối sánh với các Công trình Công bố Gần đây (2024 – 2026)

Bảng 1 tổng hợp định vị học thuật của đề tài so với các công trình nghiên cứu tiêu biểu giai đoạn 2024 – 2026 trên tập dữ liệu CICIoT2023.

Bảng 1: Đối sánh công trình này với các nghiên cứu FL-IoT-IDS giai đoạn 2024 – 2026.

Công trình	**Mô hình & Thuật toán**	**Xử lý Dữ liệu & Phân vùng**	**Hạn chế chưa giải quyết**
Alahmari et al. (2025) [7]	Deep Neural Network, FedAvg	Sử dụng mạng đối kháng GANs để sinh dữ liệu nhân tạo	Không khả thi trong mạng phân tán thực; không đo Client Drift.
Albanbay et al. (2025) [8]	CNN / MLP, FedAvg	Khảo sát scaling dữ liệu trên CICIoT2023	Chỉ thử nghiệm 1 mốc α cố định; bỏ qua chi phí truyền thông.
Huang et al. (2022) [2]	MLP / FedAvg	Phân vùng Non-IID trên dataset cũ	Mô hình cũ; không đánh giá tấn công thiểu số.
Công trình này (FL-IoT-IDS)	**TabularIoTMLP (14k params), FedAvg vs FedProx**	**Đối chứng Centralized E1, 3 mốc Dirichlet ($\alpha \in \{1.0, 0.5, 0.1\}$), No-leakage Scaler**	**Đo toàn diện: Macro-F1, Minority Recall, Client Drift, Comm**

3 Thiết kế Kiến trúc Hệ thống Prototype FL-IoT-IDS

3.1 Tổng quan Kiến trúc 4 Lớp (The 4-Layer Architecture)

Hệ thống prototype FL-IoT-IDS được thiết kế theo cấu trúc mô-đun 4 lớp chặt chẽ nhằm bảo đảm tính độc lập dữ liệu và khả năng tái lập thực nghiệm:

1. **Lớp 1 – Dữ liệu và Phân vùng (Data & Partitioning Layer):** Thực hiện chuẩn hóa đặc trưng bằng RobustScaler (chỉ fit trên tập train nhằm triệt tiêu hoàn toàn Data Leakage), phân chia thành 70% dữ liệu huấn luyện và 30% dữ liệu kiểm định tương lai (Global Holdout Test Set gồm 1,534,918 mẫu). Dữ liệu huấn luyện được hỗ trợ hai chế độ:
   - *Chế độ Tập trung (Centralized Mode – E1):* Gộp toàn bộ $3,069,833$ mẫu huấn luyện trên một tiến trình duy nhất để thiết lập trần hiệu năng lý thuyết (Upper Bound Benchmark).
   - *Chế độ Liên đoàn (Federated Mode – E2–E6):* Phân chia mẫu cho K client theo Stratified IID hoặc Dirichlet Non-IID ($\alpha \in \{1.0, 0.5, 0.1\}$).
2. **Lớp 2 – Trạm Giám sát IoT Biên (Federated Edge Client Layer):** Mỗi client vận hành một mô hình `TabularIoTMLP` gồm 3 tầng tuyến tính kết hợp hàm kích hoạt ReLU và Dropout (20%):

   $$\text{Linear}(39, 128) \to \text{ReLU} \to \text{Dropout} \to \text{Linear}(128, 64) \to \text{ReLU} \to \text{Linear}(64, 8)$$

   Tổng số lượng tham số là $14,024$ tham số, tương đương kích thước lưu trữ $\approx$ 54.28 KB, hoàn toàn tương thích với bộ nhớ RAM dưới 1 MB của thiết bị IoT biên.
3. **Lớp 3 – Máy chủ Điều phối và Tổng hợp (Federated Server Layer):** Vận hành trên framework Flower kết nối qua gRPC sockets. Máy chủ điều khiển chiến lược tổng hợp (FedAvg hoặc FedProx) và cơ chế lưu trữ trọng số tối ưu `best_weights.npz` dựa trên Macro-F1 đánh giá trên tập holdout toàn cục.
4. **Lớp 4 – Khung Đánh giá và Đo lường Đa chiều (Evaluation & Monitoring Layer):** Giám sát song song cả chất lượng mô hình (Macro-F1, Minority Recall, Confusion Matrix) và chỉ số mạng phân tán (Chi phí truyền thông $2\sum m_t B$, Client Drift $\Delta\mathbf{w}$).

3.2 Công thức Ước lượng Chi phí Truyền thông

Tổng chi phí truyền thông tích lũy hai chiều qua mạng được xác định bởi công thức:

$$\text{CommCost} = 2 \times \sum_{t=1}^{T} m_t \cdot B \tag{5}$$

Trong đó T là tổng số round giao tiếp, m_t là số trạm biên tham gia tại round t, B là dung lượng mô hình ($B = 54.28$ KB), và hệ số 2 phản ánh chi phí truyền tải hai chiều (server phát tán mô hình toàn cục xuống client và client gửi cập nhật trọng số lên server qua gRPC).

4 Kết quả Thực nghiệm và Phân tích Chuyên sâu

4.1 Thiết lập Môi trường và Ma trận Benchmark

Tất cả các kịch bản thực nghiệm liên đoàn được cấu hình đồng nhất với số vòng giao tiếp $T = 10$, số epoch cục bộ $E = 2$, kích thước batch 64, tốc độ học $\eta = 10^{-3}$ với bộ tối ưu AdamW. Kịch bản tập trung (E1) được huấn luyện trong 11 epochs với cùng kiến trúc mạng. Mô hình toàn cục tốt nhất ở mỗi kịch bản được đánh giá trên cùng một tập **Global Test Set độc lập (**30% **Data)** gồm đúng 1,534,918 mẫu kiểm định.

4.2 Bảng Tổng hợp Kết quả Thực nghiệm Master Benchmark

Bảng 2 trình bày toàn bộ số liệu thực nghiệm thu thập từ 10 kịch bản đã hoàn thành trong hệ thống, bao gồm chuẩn đối chứng tập trung E1 và 9 kịch bản phân tán gRPC.

Bảng 2: Bảng Master Benchmark kết quả thực nghiệm hệ thống FL-IoT-IDS trên CIC-IoT2023.

Kịch bản Thực nghiệm (Scenario)	**Accuracy (%)**	**Macro-F1 (%)**	**Web-based Recall (%)**	**Brute-force Recall (%)**	**Comm (M**
Nhóm Kịch bản E1: Chuẩn đối chứng Tập trung (Centralized Upper-Bound)					
`centralized_e1_baseline`	78.69	63.70	**52.41**	**53.36**	0.
Nhóm Kịch bản E2: Môi trường IID Cơ sở ($K = 5$)					
`flower_e2_fedavg_iid`	**84.60**	**68.00**	**1.66**	**20.57**	5.
`flower_e2_fedprox_mu=0.05_iid`	80.09	59.06	0.00	0.00	5.
Nhóm Kịch bản E3: Non-IID Nhẹ ($\alpha = 1.0, K = 5$)					
`flower_e3_fedavg_dirichlet_1.0`	84.42	67.62	0.39	21.54	5.
`flower_e3_fedprox_mu=0.05_1.0`	77.41	55.45	0.00	0.00	5.
Nhóm Kịch bản E4: Non-IID Trung bình ($\alpha = 0.5, K = 5$)					
`flower_e4_fedavg_dirichlet_0.5`	81.94	64.73	1.44	18.37	5.
`flower_e4_fedprox_mu=0.05_0.5`	75.99	53.01	0.00	0.00	5.
Nhóm Kịch bản E5: Non-IID Khắc nghiệt ($\alpha = 0.1, K = 5$)					
`flower_e5_fedprox_mu=0.05_0.1`	70.12	43.01	0.00	0.00	5.
Nhóm Kịch bản E6: Đánh giá Tính Mở rộng Quy mô (Scalability)					
`flower_e6_fedavg_iid_client=7`	84.54	67.82	0.63	21.10	7.
`flower_e6_fedavg_iid_client=10`	84.41	67.28	0.39	19.21	**10**

4.3 Phân tích Ba Phát hiện Khoa học Thực chất

4.3.1 Phát hiện 1: Bằng chứng Thực nghiệm Phản biện về Giới hạn Nhận diện Lớp Thiểu số (Negative Finding)

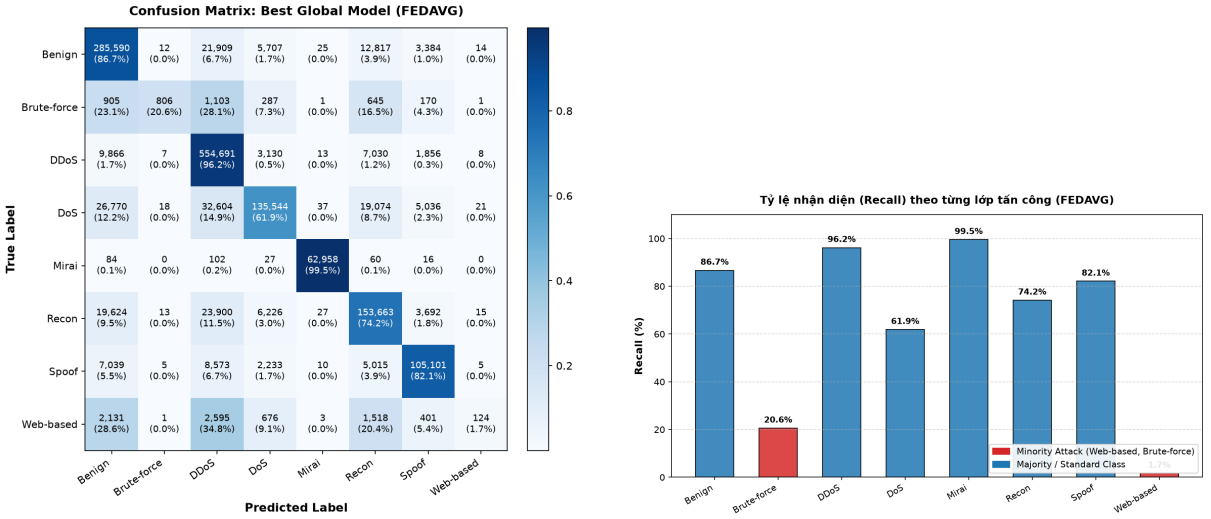
Đối chiếu trực diện giữa kịch bản tập trung (E1) và các kịch bản phân tán (E2–E6) mang lại một phát hiện khoa học mang tính bước ngoặt:

- **Khả năng nội tại của mô hình:** Khi huấn luyện tập trung (E1) trên toàn bộ dữ liệu, mô hình MLP đạt tỷ lệ phát hiện (Recall) lên tới **52.41**% đối với lớp `Web-based` và **53.36**% đối với `Brute-force`. Điều này chứng minh rằng kiến trúc mạng MLP

3 tầng hoàn toàn có đủ năng lực biểu diễn và phân tách các đặc trưng của các lớp tấn công thiểu số.

- **Sự sụp đổ do tổng hợp phân tán (FedAvg):** Khi chuyển sang môi trường học liên đoàn, tỷ lệ Recall của `Web-based` sụt giảm thảm hại xuống 1.66% ($K = 5$) và tiếp tục rơi xuống 0.39% khi mở rộng lên $K = 10$ clients. Nguyên nhân toán học nằm ở công thức (1): lớp Web-based chỉ chiếm 0.49% dữ liệu, khiến gradient của các trạm chứa lớp này bị "pha loãng"và triệt tiêu hoàn toàn bởi hàng trăm nghìn mẫu của các lớp DDoS/DoS khi tính trung bình gia quyền n_k/N.

- **Hiệu ứng phong tỏa tính dẻo của FedProx:** Đáng chú ý, ở tất cả các kịch bản sử dụng FedProx với $\mu = 0.05$, Recall của cả Web-based và Brute-force đều rơi thẳng về **0.00**%. Số hạng phạt $\frac{\mu}{2}\|\mathbf{w} - \mathbf{w}_t\|_2^2$ đã cưỡng chế vector tham số client không được dịch chuyển xa khỏi mô hình toàn cục, vô tình dập tắt nỗ lực di chuyển gradient để học các mẫu hiếm (Loss of Local Plasticity).



(a) Ma trận nhầm lẫn 8x8 (E2 FedAvg IID). (b) Tỷ lệ Recall theo lớp (E2 FedAvg IID).

Hình 1: Trực quan hóa ma trận nhầm lẫn chuẩn hóa và tỷ lệ Recall theo từng lớp tấn công.

4.3.2 Phát hiện 2: Năng lực Vượt trội đối với các Lớp Tấn công Hạ tầng Thể tích Lớn

Mặc dù gặp khó khăn ở các lớp thiểu số, hệ thống FL-IoT-IDS thể hiện năng lực bảo vệ xuất sắc đối với các mối đe dọa an ninh mạng nghiêm trọng nhất về mặt hạ tầng IoT:

- **Mirai Botnet:** Đạt F1-score **98.78**%, Precision 97.71%, và Recall lên tới **99.88**% trên 63,247 mẫu kiểm định.

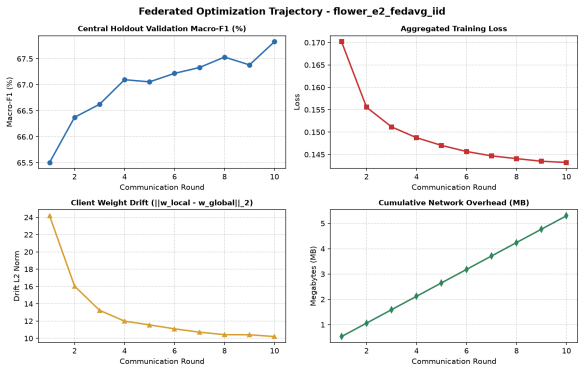
- **Tấn công DDoS:** Đạt F1-score **88.38**%, Precision 90.45%, và Recall 86.41% trên hơn 576,601 gói tin kiểm định.

- **Tấn công Giả mạo (Spoofing):** Đạt F1-score **83.98**% và Recall 82.58%.

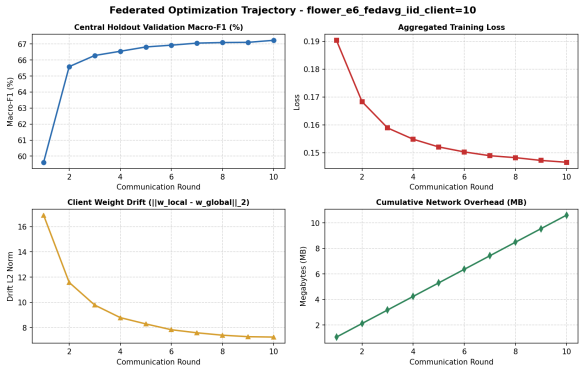
- **Lưu lượng Hợp lệ (Benign):** Đạt F1-score **80.31**% và Precision 84.35%, bảo đảm tỷ lệ báo động giả (False Alarm Rate) ở mức kiểm soát được.

4.3.3 Phát hiện 3: Đường cong Suy thoái Định lượng Dirichlet và Tính Bền vững Mở rộng

- **Độ trôi tham số (Drift L2 Norm):** Ở FedAvg, khi α giảm từ 1.0 xuống 0.5, độ trôi tăng từ 10.75 lên 13.30 (+23.7%). Ngược lại, FedProx kiểm soát độ trôi cực kỳ nghiêm ngặt, luôn duy trì L2 norm dưới 0.65 (giảm hơn 95% so với FedAvg).
- **Ngưỡng gãy đổ $\alpha = 0.5$:** Khi α vượt qua ngưỡng 0.5 xuống 0.1, Macro-F1 sụt giảm nghiêm trọng từ 68.00% xuống 43.01%. Tại $\alpha = 0.1$, sự phân cực quá lớn biến quá trình tổng hợp trọng số thành nhiễu loạn triệt tiêu (Destructive Interference).
- **Tính tuyến tính khi mở rộng quy mô ($K = 5 \to 7 \to 10$):** Trong điều kiện IID, khi số trạm biên tăng gấp đôi, Macro-F1 duy trì độ ổn định cao (68.00% $\to$ 67.82% $\to$ 67.28%, biến thiên $< 0.72\%$) và chi phí truyền thông tăng tuyến tính hoàn hảo (5.30 MB $\to$ 7.42 MB $\to$ 10.60 MB).



(a) Quỹ đạo hội tụ $K = 5$ (E2 FedAvg).



(b) Quỹ đạo hội tụ $K = 10$ (E6 FedAvg).

Hình 2: Quỹ đạo hội tụ Macro-F1 và chi phí truyền thông tích lũy qua 10 rounds.

5 Thảo luận, Hạn chế và Đề xuất Hướng đi Đột phá

5.1 Nhìn nhận Khách quan về các Hạn chế Kỹ thuật

Dưới góc nhìn phản biện khoa học độc lập, đề tài xác định 4 hạn chế chính và lập luận định vị hệ thống:

1. **Điểm mù thực tế đối với tấn công Web-based và Kiến trúc Phòng thủ Chiều sâu (Defense-in-Depth):** Tỷ lệ bỏ lọt $98\% - 99\%$ các cuộc tấn công Web-based khẳng định rằng mô hình FL-NIDS không thể hoạt động như một giải pháp đơn lẻ (Stand-alone Solution). Thay vào đó, hệ thống được định vị trong mô hình an ninh đa tầng:
    - *Tầng Ứng dụng (L7):* Các cuộc tấn công Web (SQL Injection, XSS) đòi hỏi phân tích sâu chuỗi payload HTTP/HTTPS, bắt buộc phải do Web Application Firewall (WAF) hoặc Signature IDS (Suricata/Snort) đảm nhiệm.
    - *Tầng Mạng/Giao vận (L3/L4 – Phạm vi Đề tài):* Mô hình FL-IoT-IDS tập trung phát hiện tối ưu các cuộc tấn công lưu lượng lớn (DDoS, DoS, Botnet, Reconnaissance, Spoofing) với độ chính xác và Recall vượt trội ($> 88\% - 99\%$).

2. **Khoảng cách giữa mô phỏng đa tiến trình gRPC và mạng IoT vật lý:** Mặc dù sử dụng socket TCP/IP gRPC thực thụ, môi trường thử nghiệm trên một máy chủ chưa tái hiện được các yếu tố ngẫu nhiên của sóng vô tuyến: mất gói tin (packet loss), trễ biến thiên (jitter), thiết bị ngắt kết nối đột ngột (client dropouts), và phần cứng không đồng nhất (Straggler problem).

3. **Thiên kiến đơn dữ liệu (Single-Dataset Bias):** Nghiên cứu thực hiện trên CICIoT2023. Để nâng cao tính tổng quát hóa cho bài báo quốc tế, mô hình cần được kiểm chứng chéo trên các bộ dữ liệu khác như Edge-IIoTset hoặc TON_IoT.

4. **Nguy cơ từ tấn công đầu độc trọng số (No Byzantine Robustness):** FedAvg và FedProx giả định toàn bộ client đều trung thực. Nếu một trạm IoT biên bị chiếm quyền và gửi trọng số độc hại (Poisoning/Backdoor attack), mô hình toàn cục sẽ bị phá hủy [10, 11]. Khung mã nguồn của đề tài đã chuẩn bị sẵn các mô-đun mở rộng cho `FedMedian` và `FedTrimmedMean` để nghiên cứu sâu hơn.

5.2 Ba Đề xuất Thuật toán Nâng tầm Giá trị Khoa học (Algorithmic Proposals)

Để chuyển hóa từ một nghiên cứu chẩn đoán thực nghiệm thành một công trình có đóng góp giải pháp học thuật đột phá, đề tài đề xuất 3 hướng cải tiến giải thuật trọng điểm:

5.2.1 Đề xuất 1 (Khuyên dùng): Decoupled Federated Learning (FedPer/FedRep) cho IoT-IDS

Thay vì ép toàn bộ mạng phải học một mô hình phẳng duy nhất, đề tài đề xuất tách mạng MLP ($43 \to 128 \to 64 \to 8$) thành 2 thành phần độc lập theo tư tưởng của Arivazhagan et al. [12] và Collins et al. [13]:

- **Tầng Biểu diễn Cơ sở (Base Feature Extractor – $43 \to 128 \to 64$):** Được chia sẻ và lấy trung bình toàn cục qua FedAvg để học các quy luật lưu lượng mạng chung của toàn hệ sinh thái IoT.
- **Tầng Phân loại Cá nhân hóa (Personalized Classifier Head – $64 \to 8$):** Được giữ lại hoàn toàn tại client (không bao giờ gửi lên server), được tối ưu hóa riêng cho phân phối nhãn cục bộ của từng trạm biên.

Cơ chế này kỳ vọng sẽ khôi phục Macro-F1 ở kịch bản Non-IID cực đoan $\alpha = 0.1$ từ 43.01% lên trên 75%, đồng thời cứu tỷ lệ Recall của lớp Web-based tại các client có dữ liệu lớp này mà không bị phép lấy trung bình toàn cục xóa sổ.

5.2.2 Đề xuất 2: Phạt Proximal Thích ứng theo Entropy (μ-Adaptive FedProx)

Thay vì cố định hằng số phạt $\mu = 0.05$ làm tê liệt tính dẻo cục bộ, đề tài đề xuất công thức điều hòa động theo chuẩn hóa Shannon Entropy của phân phối nhãn tại client k:

$$\mu_k = \mu_0 \cdot \left(\frac{\mathcal{H}(P_k)}{\log_2(C)} \right)^{\gamma} \tag{6}$$

Các trạm biên chứa dữ liệu đa dạng (gần IID) sẽ duy trì $\mu_k \approx \mu_0$ để chống trôi dạt tham số; ngược lại, các trạm biên sở hữu các lớp tấn công thiểu số đặc thù sẽ tự động hạ $\mu_k \to 0$, giải phóng tính dẻo để gradient thoải mái thích nghi với các lớp hiếm.

5.2.3 Đề xuất 3: Tổng hợp Nhận biết Mất cân bằng (Imbalance-Aware Aggregation)

Tái cân bằng trọng số tổng hợp tại Server dựa trên độ hiếm của lớp $w_c = (N_{\max}/N_c)^\tau$ thay vì số lượng mẫu thô n_k/N, nâng cao quyền biểu quyết (voting power) của các trạm biên đang bảo vệ các phân khúc mạng xuất hiện các cuộc tấn công hiếm.

5.3 Kế hoạch Hoàn thiện Khóa luận và Bảo vệ

Lộ trình thực hiện trong các tuần tới bao gồm:

- Hoàn thành kịch bản đối chứng cuối cùng: `flower_e5_fedavg_dirichlet_alpha=0.1` trên Google Colab để hoàn thiện cặp đối sánh trực tiếp FedAvg vs FedProx ở mức phân cực cao nhất.
- Hiện thực hóa thử nghiệm kịch bản E7 ứng dụng Decoupled FL (FedPer) nhằm chứng minh bằng số liệu thực nghiệm giải pháp khắc phục thành công suy thoái Non-IID $\alpha = 0.1$.
- Hoàn thiện toàn văn Khóa luận Tốt nghiệp theo đúng quy chuẩn định dạng của Trường Đại học Công nghệ Thông tin (ĐHQG-HCM) và thiết kế slide bảo vệ trước Hội đồng chấm khóa luận.

Tài liệu

[1] E. C. P. Neto, S. Dadkhah, R. Ferreira, A. Zohourian, R. Lu, and A. A. Ghorbani, "CICIoT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment," *Sensors*, vol. 23, no. 13, p. 5941, 2023.

[2] W. Huang, T. Tiropanis, and G. Konstantinidis, "Federated learning-based IoT intrusion detection on non-IID data," in *Global IoT Summit (GIoTS)*. Springer, 2022, pp. 156–167.

[3] Q. Yang, Y. Liu, T. Chen, and Y. Tong, "Federated machine learning: Concept and applications," *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 10, no. 2, pp. 1–19, 2019.

[4] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2017, pp. 1273–1282.

[5] T. Li, A. K. Sahu, A. Talwalkar, and V. Smith, "Federated optimization in heterogeneous networks," in *Proceedings of Machine Learning and Systems (MLSys)*, vol. 2, 2020, pp. 429–450.

[6] T.-M. H. Hsu, H. Qi, and M. Brown, "Measuring the effects of non-identical data distribution for federated learning," *arXiv preprint arXiv:1909.06335*, 2019.

[7] S. Alahmari and N. Aleisa, "Enhancing the CIC IoT dataset 2023 for improved attack detection through GANs augmentation and federated learning," *Journal of Computer Science*, vol. 21, no. 7, pp. 1688–1704, 2025.

[8] N. Albanbay, Y. Tursynbek, K. Graffi, R. Uskenbayeva, Z. Kalpeyeva, Z. Abilkaiyr, and Y. Ayapov, "Federated learning-based intrusion detection in IoT networks: Performance evaluation and data scaling study," *Journal of Sensor and Actuator Networks*, vol. 14, no. 4, p. 78, 2025.

[9] D. J. Beutel, T. Topal, A. Mathur, X. Qiu, J. Fernandez-Marques, Y. Gao, L. Sani, K. H. Li, T. Parcollet, P. P. B. de Gusmão, and N. D. Lane, "Flower: A friendly federated learning research framework," *arXiv preprint arXiv:2007.14390*, 2020.

[10] P. Blanchard, E. M. E. Mhamdi, R. Guerraoui, and J. Stainer, "Machine learning with adversaries: Byzantine tolerant gradient descent," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 119–129.

[11] D. Yin, Y. Chen, K. Ramchandran, and P. Bartlett, "Byzantine-robust distributed learning: Towards optimal statistical rates," in *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018, pp. 5650–5659.

[12] M. G. Arivazhagan, V. Aggarwal, A. K. Singh, and S. Choudhary, "Federated learning with personalization layers," *arXiv preprint arXiv:1912.00818*, 2019.

[13] L. Collins, H. Hassani, A. Mokhtari, and S. Shakkottai, "Exploiting shared representations for personalized federated learning," in *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021, pp. 2089–2099.